



**Universitatea Națională de Știință și Tehnologie din București**

**Facultatea de Automatică și Calculatoare**

**Departamentul de Automatică și Ingineria Sistemelor**

# **LUCRARE DE LICENȚĂ**

**Control PID multi-dimensional pentru sisteme  
neliniare**

**Absolvent**

**Vlad-Gabriel GRIGORE**

**Coordonatori**

**Prof. Dr. Ing. Dan ȘTEFĂNOIU**

**Prof. Dr. Ing. Janetta CULIȚĂ**

**București, 2025**



### *Mulțumiri*

*Doresc să le mulțumesc în mod sincer și respectuos domnului profesor Dan Ștefănoiu și doamnei profesor Janetta Culiță pentru sprijinul acordat în realizarea acestei lucrări de licență.*

*Îndrumarea lor profesională, observațiile pertinente și deschiderea față de ideile propuse au avut un impact esențial în dezvoltarea acestui proiect. Le sunt recunoscător pentru răbdarea, timpul și implicarea de care au dat dovadă pe tot parcursul colaborării.*



# Cuprins

|                                                                        |     |
|------------------------------------------------------------------------|-----|
| Listă de figuri .....                                                  | III |
| Listă de tabele .....                                                  | IV  |
| Listă de acronime .....                                                | V   |
| 1 Introducere.....                                                     | 1   |
| 2 Modele de tip ARX și NARX pentru sisteme multi-variabile .....       | 3   |
| 2.1 Modele de identificare de tip ARX .....                            | 3   |
| 2.1.1 Modelul SISO-ARX.....                                            | 3   |
| 2.1.2 Extindere la modele MISO-ARX.....                                | 4   |
| 2.1.3 Avantaje, limitări și utilizări ale modelelor MISO-ARX .....     | 5   |
| 2.2 Modele de identificare de tip NARX.....                            | 6   |
| 2.2.1 Modelul SISO-NARX .....                                          | 6   |
| 2.2.2 Extindere la modele MISO-NARX .....                              | 8   |
| 2.2.3 Avantaje, limitări și utilizări ale modelelor MISO-NARX.....     | 10  |
| 2.3 Metode de identificare și validare ale modelelor ARX și NARX ..... | 12  |
| 2.4 Determinarea indicilor structurali optimali ai modelelor .....     | 13  |
| 2.5 Algoritmul Grey Wolf Optimizer (GWO) .....                         | 17  |
| 2.5.1 Privire generală asupra metaeuristicilor.....                    | 17  |
| 2.5.2 Principiul metaeuristicii GWO.....                               | 18  |
| 2.5.3 Modelul matematic al metaeuristicii GWO .....                    | 18  |
| 2.5.4 Pașii principali ai algoritmului GWO.....                        | 22  |
| 2.5.5 Avantaje și limitări ale algoritmului GWO .....                  | 23  |
| 3 Regulatorul PID multi-variabil discret .....                         | 23  |
| 3.1 Regulatorul PID în timp continuu.....                              | 23  |
| 3.2 Discretizarea regulatorul PID prin Metoda Biliniară (Tustin) ..... | 24  |
| 3.3 Determinarea regulatorului PID optimal cu ajutorul GWO .....       | 27  |
| 3.4 Schema de control multi-variabil cu regulatorul PID discret.....   | 30  |
| 4 Studiu de caz: instalația didactică ASTANK2 .....                    | 31  |
| 4.1 Scurtă descriere a instalației ASTANK2.....                        | 31  |
| 4.1.1 Prezentare generală .....                                        | 31  |
| 4.1.2 Caracteristici funcționale și constrângeri .....                 | 32  |
| 4.2 Organizarea simulărilor.....                                       | 34  |

|     |                                 |    |
|-----|---------------------------------|----|
| 4.3 | Rezultate de identificare ..... | 37 |
| 4.4 | Rezultate de control .....      | 41 |
| 5   | Concluzii și perspective .....  | 45 |
| 6   | Contribuții personale.....      | 46 |
|     | Bibliografie .....              | 47 |

## Listă de figuri

|                                                                                                                                                |    |
|------------------------------------------------------------------------------------------------------------------------------------------------|----|
| Figura 2.1 Structura bloc a modelului SISO-NARX. ....                                                                                          | 9  |
| Figura 2.2 Schema funcțională a modelului 2-MISO-NARX, utilizat pentru<br>identificarea instalației ASTANK2. ....                              | 11 |
| Figura 3.1 Schema control automat folosind regulatorul PID multi-dimensional.....                                                              | 24 |
| Figura 3.2 Schema control automat folosind regulatorul PID multi-dimensional.....                                                              | 30 |
| Figura 4.1 Schema structurală a instalației didactice ASTANK2. (Imagine preluată<br>din publicația [CuStDu-2015], cu acordul autorilor.) ..... | 31 |
| Figura 4.2 Zona de referințe și comenzi statice admisibile ale instalației ASTANK2.                                                            | 33 |
| Figura 4.3 Schema SIMULINK a sub-sistemului MISO asociat canalului 1 de ieșire.<br>.....                                                       | 35 |
| Figura 4.4 Schema SIMULINK a sub-sistemului MISO asociat canalului 2 de ieșire.<br>.....                                                       | 35 |
| Figura 4.5 Blocurile reglatoare discrete responsabile de sinteza comenzilor. ....                                                              | 35 |
| Figura 4.6 Componentele interne ale blocurilor reglatoare discrete. ....                                                                       | 36 |
| Figura 4.7 Semnale de stimul generate și de ieșire achiziționate din instalația<br>ASTANK2, pentru faza de identificare. ....                  | 38 |
| Figura 4.8 Semnale de stimul generate și de ieșire achiziționate din instalația<br>ASTANK2, pentru faza de validare. ....                      | 38 |
| Figura 4.9 Performanțele de identificare și validare ale modelelor .....                                                                       | 40 |
| Figura 4.10 Performanțele de control și urmărire de referințe constante ale<br>modelelor .....                                                 | 42 |
| Figura 4.11 Performanțele de control și urmărire de referințe constante ale modelului<br>.....                                                 | 44 |

## Listă de tabele

|                                                                                 |    |
|---------------------------------------------------------------------------------|----|
| Tabelul 4.1 Un punct nominal de funcționare al instalației ASTANK2. ....        | 34 |
| Tabelul 4.2 Indicii structurali optimali ai modelului 2-MISO-ARX. ....          | 37 |
| Tabelul 4.3 Indicii structurali majori optimali ai modelului 2-MISO-NARX.....   | 37 |
| Tabelul 4.4 Indicii structurali minori optimali ai modelului 2-MISO-NARX.....   | 38 |
| Tabelul 4.5 Un punct nominal de funcționare obținut cu modelul 2-MISO-ARX. .... | 43 |



## Listă de acronime

|          |                                                     |
|----------|-----------------------------------------------------|
| ARMA     | Auto-Regressive Moving Average                      |
| ARMAX    | Auto-Regressive Moving Average with eXogenous input |
| ARX      | Auto-Regressive with eXogenous input                |
| GWO      | Grey Wolf Optimizer                                 |
| MCMMP    | Metoda Celor Mai Mici Pătrate                       |
| MCMMP-MP | MCMMP Multi-Pas                                     |
| MIMO     | Multiple Input, Multiple Output                     |
| MISO     | Multiple Input, Single Output                       |
| MMEP     | Metoda Minimizării Erorii de Predicție              |
| NARX     | Nonlinear Auto-Regressive with eXogenous inputs     |
| SISO     | Single Input, Single Output                         |
| SNR      | Signal-to-Noise Ratio                               |
| TL       | Transformata Laplace                                |
| TT       | Transformarea lui Tustin                            |
| TZ       | Transformata Z                                      |



# 1 Introducere

Într-un cadru industrial aflat într-o continuă evoluție, sistemele dinamice multi-dimensionale (în mod uzual, de tip MISO (*Multiple Input, Single Output*) sau MIMO (*Multiple Input, Multiple Output*) [StCuSt-2005] capătă un rol tot mai pregnant în automatizarea proceselor complexe. Controlul precis al acestor sisteme impune nu doar o înțelegere profundă a interacțiunilor dintre variabilele de intrare și de ieșire, ci și capacitatea de a surprinde caracterul adesea neliniar al comportamentului lor.

Problema tratată în această lucrare pornește de la nevoia de identificare riguroasă și suficient de precisă a dinamicii unui astfel de sistem multi-dimensional, având drept obiectiv principal proiectarea unui algoritm de control din familia PID (Proportional-Integral-Derivativ), capabil să răspundă în mod eficient cerințelor de performanță și stabilitate. Deși modelele liniare asociate sistemelor dinamice oferă soluții rapide și implementări convenabile, acestea se dovedesc a fi insuficient de precise în cazul unor sisteme reale, mai ales de complexitate ridicată și/sau cu un comportament neliniar pronunțat, reducând precizia și chiar robustețea blocului de control automat.

În acest sens, motivația lucrării se fundamentează pe depășirea limitărilor impuse de metodele clasice de reglare PID. După cum e precizat în [StCu-2021], ajustarea manuală a parametrilor sau utilizarea tehnicilor empirice, precum cele propuse de Ziegler-Nichols ori Cohen-Coon, nu mai pot susține cerințele actuale ale sistemelor dinamice avansate. Astfel, se impune adoptarea unor metode moderne, flexibile și robuste, care să permită o optimizare adaptată fiecărui canal de control în parte.

Lucrarea de față propune utilizarea algoritmului metaeuristic *Grey Wolf Optimizer* (GWO) pentru găsirea parametrilor optimali ai unui regulator PID aplicat unui sistem neliniar. Cazul de studiu îl constituie instalația didactică hidraulică ASTANK2, care este un sistem cu două intrări și două ieșiri. Această platformă experimentală oferă un cadru ideal de testare, datorită complexității geometrice, interacțiunilor hidraulice și comportamentului său neliniar. Obiectivul este obținerea unui control PID multi-dimensional optimal, stabil, rapid și cu un minim de erori staționare (în condiții de perturbații stocastice exogene), fără a decupla canalele de control și fără a recurge la metode empirice de proiectare sau simplificări excesive.

Prin integrarea modelării matematice în mediul MATLAB–SIMULINK și a unui algoritm de optimizare inspirat din comportamentul unor entități vii (GWO), lucrarea urmărește să evidențieze avantajele unei abordări moderne în proiectarea reguletoarelor PID pentru sisteme neliniare MIMO.

Astfel de abordări nu constituie o premieră în comunitatea științifică. Există o serie de articole publicate în domeniul identificării și controlului metaeuristice. Printre cele mai recente, se pot aminti [RoMeVi-2020], [StCu-2020] sau [StCu-2021]. De asemenea, problematica succint enunțată mai sus a fost abordată și în cadrul altor proiecte de licență sau disertație, unde absolvenții respectivi au oferit diferite soluții. Soluția din acest proiect de licență este, după cunoștința mea, originală și nu se regăsește nici în articolele publicate, nici în lucrările de finalizare a studiilor pe care le-am consultat.

Lucrarea de față este structurată astfel. După această scurtă introducere, capitolul al doilea este dedicat prezentării modelelor de identificare utilizate spre comparație, împreună cu metodele de estimare a parametrilor și cu maniera de optimizare a indicilor structurali. Ambele modele sunt de tip multi-MISO, în sensul că sistemul este modelat ca o colecție de blocuri având câte o ieșire, dar care sunt stimulate cu toate intrările. În cazul instalației ASTANK2, modelul este format din două

blocuri MISO, fiecare cu câte două intrări. Unul dintre modele este liniar (MISO-ARX), iar celălalt este neliniar (MISO-NARX). Identificarea acestor modele se bazează pe Metoda Celor Mai Mici Pătrate (MCMMP), care este succint prezentată în cadrul capitolului. O problemă importantă o constituie determinarea indicilor structurali optimali ai modelelor (care, cel puțin în cazul modelului NARX, pot fi în număr destul de mare). Pentru rezolvarea ei, a fost definit un criteriu de optimizare dedicat sistemelor multi-dimensionale și s-a apelat la metaeuristica GWO (la rândul ei, descrisă succint în cadrul capitolului).

În Capitolul 3, se abordează problema proiectării regulatorului bidimensional optimal. Structura regulatorului este aleasă ținând cont că, deoarece modelele de identificare sunt discrete (exprimate în timp discret), parametri acestuia trebuie să fie alocați unor matrici de transfer discrete. De aceea se pleacă de la regulatorul MIMO-PID în timp continuu, care se discretizează folosind Metoda biliniară (Tustin). Cu toate acestea, pentru găsirea regulatorului optimal, se folosesc matricile din exprimarea în timp continuu, deoarece ele au mai puțini parametri necunoscuți. Este definit un nou criteriu de optimizare, care ține cont de necesitatea ca ieșirile sistemului să urmărească referințe de tip treaptă, pe baza unor comenzi suficient de netede și nesaturate. Pe baza acestuia, se determină regulatorul PID optimal, din nou cu ajutorul metaeuristicii GWO. În finalul capitolului, este prezentată schema de reglare automată în buclă închisă folosind regulatorul PID discret.

Capitolul al patrulea prezintă rezultatele de simulare obținute folosind date reale achiziționate în cursul funcționării instalației ASTANK2. Aceste date au stat la baza obținerii modelelor de identificare optimale, ale căror performanțe sunt ilustrate. În continuare, sunt afișate o serie de grafice și informații comparative privind rezultatele de simulare în buclă închisă, folosind modelele de identificare și regulatoarele PID optimale determinate corespunzător.

Lucrarea se încheie cu o serie de concluzii și câteva perspective de abordare viitoare. O lista de contribuții personale este de asemenea anexată, înainte de lista bibliografică.

## 2 Modele de tip ARX și NARX pentru sisteme multi-variabile

### 2.1 Modele de identificare de tip ARX

#### 2.1.1 Modelul SISO-ARX

Modelele autoregresive cu medie alunecătoare și intrări exogene (ARMAX – *Auto-Regressive Moving Average with eXogenous input*) fac parte din clasa modelelor liniare utilizate frecvent în Identificarea Sistemelor dinamice discrete [StCuSt-2005]. Acestea permit descrierea relației cauzale dintre ieșire și valorile trecute ale acesteia, precum și influența istorică a intrărilor exogene, completând totodată modelarea cu o componentă destinată filtrării zgomotului. Datorită structurii lor flexibile, modelele ARMAX pot surprinde atât comportamentul determinist al sistemului, cât și efectele perturbațiilor aleatoare.

Structura generală a unui model ARMAX pentru un sistem cu o singură intrare și o singură ieșire (SISO) este exprimată astfel:

$$\begin{cases} A(q^{-1})y[n] = B(q^{-1})u[n] + C(q^{-1})e[n] \\ E\{e[n]e[m]\} = \lambda^2 \delta_0[n-m], \quad \forall n, m \in \mathbb{N}, \end{cases} \quad (2.1)$$

unde:

- $y$  este ieșirea sistemului;
- $u$  este semnalul de intrare;
- $e$  este un zgomotul de medie nulă și varianță  $\lambda^2$ ;
- $E$  este operatorul de mediere statistică;
- $\delta_0$  reprezintă impulsul Kronecker;
- $A, B$  și  $C$  sunt polinoamele sistemului de forma:

$$\begin{cases} A(q^{-1}) = 1 + a_1 q^{-1} + a_2 q^{-2} + \dots + a_{na} q^{-na} \\ B(q^{-1}) = b_1 q^{-1} + b_2 q^{-2} + \dots + b_{nb} q^{-nb} \\ C(q^{-1}) = 1 + c_1 q^{-1} + c_2 q^{-2} + \dots + c_{nc} q^{-nc} \end{cases}, \quad (2.2)$$

iar  $q^{-1}$  este operatorul de întârziere cu un pas.

Din ecuația (2.1), semnalul de ieșire poate fi exprimat explicit ca sumă între o componentă utilă (deterministă) și o componentă de zgomot:

$$y[n] = \frac{B(q^{-1})}{A(q^{-1})}u[n] + \frac{C(q^{-1})}{A(q^{-1})}e[n] = y_u[n] + v[n], \quad \forall n \in \mathbb{N}, \quad (2.3)$$

unde:

- $y_u$  reprezintă partea deterministă a răspunsului sistemului;
- $v$  este componenta de zgomot, rezultată prin filtrarea zgomotului alb cu filtrul  $C/A$ .

Modelul ARX este obținut ca o simplificare a modelului ARMAX, prin alegerea  $C(q^{-1}) = 1$ , ceea ce implică:

$$A(q^{-1})y[n] = B(q^{-1})u[n] + e[n], \quad \forall n \in \mathbb{N}. \quad (2.4)$$

Această formă este utilizată frecvent în practică, datorită simplității sale structurale și a eficienței estimării parametrilor prin metode directe, precum Metoda Celor Mai Mici Pătrate (MCMMP), care oferă stabilitate numerică și o implementare rapidă. Deși modelul ARX presupune o reprezentare mai puțin fidelă a componentei stocastice, el continuă să fie o alegere robustă în aplicații unde interesul principal este modelarea comportamentului determinist al sistemului, iar influențele perturbatoare pot fi considerate neesențiale, moderate sau dificil de caracterizat în mod explicit.

### 2.1.2 Extindere la modele MISO-ARX

În practică, majoritatea sistemelor tehnice prezintă o arhitectură multivariabilă, în care o ieșire este influențată simultan de mai multe intrări. În astfel de cazuri, modelul ARX, ce este în esență un model SISO, poate fi extins într-o configurație MIMO păstrând caracterul autoregresiv și liniar, dar adaptând structura matematică pentru a integra influențele distincte ale fiecărei intrări asupra ieșirilor analizate. Cu toate acestea, modelele MIMO sunt dificil de identificat. În multe aplicații (mai ales în cele unde ieșirile nu se influențează reciproc sau influențele dintre ele sunt neglijabile), s-a constatat că modelul MIMO poate fi aproximat cu o bună precizie printr-o colecție de modele MISO, numită și *multi-MISO*.

Forma generalizată a unui model ARX cu  $nu$  intrări și  $ny$  ieșiri, în configurație multi-MISO, este exprimată astfel, pentru  $\forall n \in \mathbb{N}$ :

$$\left\{ \begin{array}{l} y_1[n] = \underbrace{\frac{B_{1,1}(q^{-1})}{A_1(q^{-1})}u_1[n] + \frac{B_{1,2}(q^{-1})}{A_1(q^{-1})}u_2[n] + \dots + \frac{B_{1,nu}(q^{-1})}{A_1(q^{-1})}u_{nu}[n]}_{y_{1,u}[n]} + \underbrace{\frac{1}{A_1(q^{-1})}e_1[n]}_{v_1[n]} \\ \vdots \\ y_j[n] = \underbrace{\frac{B_{j,1}(q^{-1})}{A_j(q^{-1})}u_1[n] + \frac{B_{j,2}(q^{-1})}{A_j(q^{-1})}u_2[n] + \dots + \frac{B_{j,nu}(q^{-1})}{A_j(q^{-1})}u_{nu}[n]}_{y_{j,u}[n]} + \underbrace{\frac{1}{A_j(q^{-1})}e_j[n]}_{v_j[n]} \\ \vdots \\ y_{ny}[n] = \underbrace{\frac{B_{ny,1}(q^{-1})}{A_{ny}(q^{-1})}u_1[n] + \frac{B_{ny,2}(q^{-1})}{A_{ny}(q^{-1})}u_2[n] + \dots + \frac{B_{ny,nu}(q^{-1})}{A_{ny}(q^{-1})}u_{nu}[n]}_{y_{ny,u}[n]} + \underbrace{\frac{1}{A_{ny}(q^{-1})}e_{ny}[n]}_{v_{ny}[n]} \end{array} \right. , \quad (2.5)$$

unde:

- $y_j$ ,  $j \in \overline{1, ny}$  reprezintă semnalul de ieșire de pe canalul  $j$ ;
- $u_i$ ,  $i \in \overline{1, nu}$  este semnalul de intrare de pe canalul  $i$ ;
- polinomul  $A_j$  este corespunzător ieșirii  $y_j$ , iar polinomul  $B_{i,j}$  este corespunzător intrării  $u_i$  și ieșirii  $y_j$ , ambele având structura similară cu cele prezentate în sub-sețiunea precedentă.
- $e_j$  denotă zgomotul alb de pe canalul  $j$ .

Deoarece modelul ARX nu reușește să descrie cu precizie componenta stocastică a sistemului, în special în prezența zgomotului colorat, se consideră că semnalul de ieșire include o contribuție reziduală suplimentară, notată cu  $v_j$ . Aceasta este definită

ca diferența dintre semnalul achiziționat  $y_j$  și componenta utilă a modelului,  $y_{j,u}$ , deterministă:

$$v_j \equiv y_j - y_{j,u}, \quad \forall j \in \overline{1, ny}. \quad (2.6)$$

Într-o a doua etapă, această componentă de zgomot este modelată separat, utilizând un model de tip ARMA, care permite surprinderea caracteristicilor statistice ale perturbației filtrate:

$$v_j \equiv \frac{C_j(q^{-1})}{D_j(q^{-1})} e_j, \quad \forall j \in \overline{1, ny}, \quad (2.7)$$

unde:

$$\begin{cases} C_j(q^{-1}) = 1 + c_{j,1}q^{-1} + c_{j,2}q^{-2} + \dots + c_{j,nc_j}q^{-nc_j} \\ D_j(q^{-1}) = 1 + d_{j,1}q^{-1} + d_{j,2}q^{-2} + \dots + d_{j,nd_j}q^{-nd_j} \end{cases} \quad (2.8)$$

Astfel, fiecare canal de ieșire este descris printr-un model autoregresiv propriu pentru partea deterministă (MISO-ARX), completat de un model SISO-ARMA separat pentru zgomotul rezidual. Această abordare etapizată permite o identificare mai precisă și modulară a sistemelor multivariable, în special atunci când zgomotul nu poate fi considerat alb sau necorelat cu intrările.

### 2.1.3 Avantaje, limitări și utilizări ale modelelor MISO-ARX

Având la bază această abordare fragmentară, modelul MISO-ARX oferă o soluție practică și echilibrată în procesul de identificare a sistemelor liniare multivariable. Prin separarea clară a influențelor multiple asupra fiecărei ieșiri, se permite construirea unor modele stabile și eficiente în redarea caracteristicii dinamice a sistemului studiat.

Unul dintre principalele avantaje constă în eficiența estimării parametrilor, realizabilă prin metode directe, cu stabilitate numerică ridicată. În plus, caracterul său modular susține o calibrare flexibilă și adaptabilă, fiind ideal în contexte unde arhitectura sistemului poate suferi modificări.

Conform [SCVV-2024], acest tip de model este potrivit în situații în care:

- dinamica sistemului poate fi aproximată prin relații liniare sau liniarizabile;
- datele de intrare și ieșire sunt bine măsurate, iar zgomotul nu domină comportamentul părții utile;
- complexitatea modelului trebuie să rămână redusă, mai ales în aplicații de control în timp real.

Pe de altă parte, modelul MISO-ARX nu este lipsit de limitări. Structura sa liniară nu permite captarea comportamentelor profund neliniare sau dependente de regimuri multiple de funcționare. De asemenea, presupunerea că zgomotul este necorelat cu intrările poate fi restrictivă în aplicații reale, iar performanța estimării poate scădea în prezența unor cuplaje strânse între variabile sau a întârzierilor distribuite.

Modelul MISO-ARX se dovedește util în numeroase aplicații practice, în special ca etapă preliminară de identificare a comportamentului sistemelor multivariable. El furnizează o descriere clară și suficient de fidelă în situațiile în care relațiile dintre intrări și ieșiri pot fi reprezentate liniar.

În cazul instalației hidraulice ASTANK2, sistemul este compus din două rezervoare interconectate, alimentate de pompe controlate independent. Tensiunile aplicate acționează ca intrări, influențând nivelurile de lichid din cele două vase. Al doilea rezervor manifestă un comportament apropiat de cel liniar, în timp ce primul

introduce neliniarități semnificative, cauzate în special de forma sa neregulată, cu o fațetă înclinată.

În acest context, modelul MISO-ARX permite o aproximare adecvată a comportamentului global, suficientă pentru implementarea unor scheme de control, precum cele bazate pe regulatoare PID optimizate. Simplitatea metodei favorizează integrarea rapidă în aplicații de timp real, iar interpretabilitatea modelului sprijină analiza și ajustarea sistemului.

În situațiile în care complexitatea dinamicii devine relevantă, iar neliniaritățile nu mai pot fi ignorate, acest model poate fi extins natural către formulări de tip NARX (ARX neliniar), oferind un nivel suplimentar de fidelitate și precizie.

## 2.2 Modele de identificare de tip NARX

### 2.2.1 Modelul SISO-NARX

Modelele de tip NARMAX (*Nonlinear Auto-Regressive Moving Average with eXogenous input*) constituie o extindere conceptuală și aplicativă a modelelor liniare ARMAX, fiind dezvoltate pentru a surprinde comportamentele neliniare caracteristice multor sisteme dinamice reale. Spre deosebire de modelele ARMAX, care se bazează pe o combinație liniară de regresori asociați ieșirii, intrării și zgomotului, modelele NARMAX îmbunătățesc această relație cu o funcție neliniară capabilă să coreleze istoricul variabilelor sistemului cu evoluția sa actuală, prin adăugarea unor termeni dedicați prelucrării unor produse de semnale.

În configurația SISO, modelul NARMAX poate fi formulat ca o funcție polinomială extinsă, ce nu se limitează la termeni autoregresivi simpli, ci include și produse între regresori, astfel încât să surprindă interacțiuni neliniare de ordin superior. Forma generală a unei asemenea expresii, așa cum este prezentată în [HaKe-1999] sau [SCVV-2024], este următoarea:

$$\begin{cases} A(q^{-1})y[n] + \sum_{p=0}^{P-1} A_p(q^{-1})y[n]y[n-p] = \\ \quad = B(q^{-1})u[n] + \sum_{m=0}^{M-1} B_m(q^{-1})u[n]u[n-m] + \sum_{k=0}^{K-1} D_k(q^{-1})y[n]u[n-k] + C(q^{-1})e[n] \\ E\{e[n]e[m]\} = \lambda^2 \delta[n-m], \quad \forall n, m \in \mathbb{N}. \end{cases} \quad (2.9)$$

Se observă că modelul ARMAX este încorporat ca un caz particular în modelul NARMAX (2.9). Termenii suplimentari introduși evidențiază caracterul neliniar al modelului, specific prin produse între variabilele de intrare și ieșire, care sunt apoi prelucrate prin intermediul unor filtre polinomiale corespunzătoare. Pentru a formaliza aceste interacțiuni, modelul NARMAX utilizează o serie de polinoame distincte, asociate fiecărei combinații relevante dintre semnalele întârziate. Astfel, în definiția (2.9) apar următoarele clase de polinoame:

$$\begin{cases} A_p(q^{-1}) = a_{p,1}q^{-1} + a_{p,2}q^{-2} + \dots + a_{p,n_{a_p}}q^{-n_{a_p}}, \quad \forall p \in \overline{0, P-1} \\ B_m(q^{-1}) = b_{m,1}q^{-1} + b_{m,2}q^{-2} + \dots + b_{m,n_{b_m}}q^{-n_{b_m}}, \quad \forall m \in \overline{0, M-1} \\ D_k(q^{-1}) = d_{k,1}q^{-1} + d_{k,2}q^{-2} + \dots + d_{k,n_{d_k}}q^{-n_{d_k}}, \quad \forall k \in \overline{0, K-1} \end{cases} \quad (2.10)$$

În funcție de ordinea întârzierilor care apar în produsele de semnale, modelul NARMAX este guvernat de două seturi de indici structurali:

- **indici majori** ( $P, M, K$ ), care stabilesc câte polinoame sunt necesare pentru fiecare familie de termeni neliniari:  $P$  pentru produse ieșire-ieșire,



$M$  pentru produse intrare–intrare, respectiv  $K$  pentru produse ieșire–intrare.

- **indici minori** ( $na_0, \dots, na_{p-1}, nb_0, \dots, nb_{M-1}, nd_0, \dots, nd_{K-1}$ ), care fixează ordinul fiecărui polinom individual și, implicit, capacitatea de memorare pe care modelul o folosește pentru a procesa informația.

În analogie cu polinomul  $B$  din definiția modelului ARMAX (2.1), toate polinoamele utile sunt construite fără termen liber, garantând că fiecare componentă a modelului prelucrează semnalele numai după cel puțin un pas de întârziere. Excepția o constituie polinomul  $C$ , care acționează asupra zgomotului și conține în mod necesar un termen constant, deoarece perturbațiile pot influența instantaneu ieșirea.

Prin această arhitectură, valoarea curentă  $y[n]$  este separată strict de toate eșantioanele întârziate (inclusiv zgomotul  $e[n]$ ), ceea ce elimină buclele algebrice și permite implementarea directă a relațiilor (2.1) și (2.9) în schema de filtrare. Toți coeficienții polinomiali, la fel ca varianța zgomotului  $\lambda^2$ , rămân necunoscuți și trebuie estimați experimental. În situația specială în care se impune ca polinomul  $C$  să fie unitar, modelul se reduce la forma clasică NARX cu care se poate continua procesul de identificare a sistemului analizat. Eliminarea polinomului  $C$  din cadrul modelului NARMAX aduce o simplificare majoră privind algoritmul numeric de identificare, bazat pe MCMMP.

Astfel, cu toate că modelul NARX are un comportament bazat pe relații de neliniaritate în raport cu semnalele de intrare și ieșire, el rămâne un model liniar în raport cu parametrii (coeficienții polinoamelor (2.10)). Această particularitate valoroasă face posibilă reformularea modelului într-o expresie compactă, prin reunirea tuturor coeficienților într-un vector unitar de parametri.

$$\theta = \begin{bmatrix} \mathbf{a}^T & \mathbf{a}_0^T & \cdots & \mathbf{a}_{p-1}^T & \mathbf{b}^T & \mathbf{b}_0^T & \cdots & \mathbf{b}_{M-1}^T & \mathbf{b}_0^T & \cdots & \mathbf{b}_{K-1}^T \end{bmatrix}^T \quad (2.11)$$

Cu notația (2.11), întreaga complexitate a modelului este capturată într-o formă clară și coerentă: Cu notațiile care decurg în mod firesc din ecuațiile prezentate anterior, „ $\mathbf{a}$ ” reprezintă vectorul coloană al coeficienților polinoamelor  $A$ ; primul vector include termenii liniari, în timp ce următorii vectori se referă la termenii neliniari prelucrați de polinoamele  $A$ . În mod similar, notația „ $\mathbf{b}$ ” grupează toți coeficienții asociați polinoamelor  $B$ , iar notația „ $\mathbf{d}$ ” reunește coeficienții corespunzători polinoamelor  $D$ , reflectând influențele combinate ale produselor între intrare și ieșire.

Odată structurat vectorul  $\theta$ , modelul poate fi exprimat elegant sub forma unei ecuații de regresie liniară:

$$y[n] = \phi^T[n] \theta + e[n], \quad \forall n \in \mathbb{N}, \quad (2.12)$$

unde  $\phi[n]$  ( $n \in \mathbb{N}$ ) este vectorul de regresori, conținând toate combinațiile relevante între eșantioanele întârziate ale semnalelor de intrare și ieșire, având următoarea structură:

$$\begin{aligned} \phi[n] = & \begin{bmatrix} \phi_y^T[n] & \phi_{y,0}^T[n] & \cdots & \phi_{y,p-1}^T[n] & | & \\ \phi_u^T[n] & \phi_{u,0}^T[n] & \cdots & \phi_{u,M-1}^T[n] & | & \\ \phi_{yu,0}^T[n] & \cdots & \phi_{yu,K-1}^T[n] \end{bmatrix}^T, \quad \forall n \in \mathbb{N}, \end{aligned} \quad (2.13)$$

care, la rândul lor, sunt compuse din următorii termeni:

$$\left\{ \begin{aligned} \Phi_y^T[n] &= [-y[n-1] \quad \cdots \quad -y[n-na]] \\ \Phi_{y,p}^T[n] &= [-y[n-1]y[n-p-1] \quad \cdots \quad -y[n-na_p]y[n-p-na_p]], \quad \forall p \in \overline{0, P-1} \\ \Phi_u^T[n] &= [u[n-1] \quad \cdots \quad u[n-nb]] \\ \Phi_{u,m}^T[n] &= [u[n-1]u[n-m-1] \quad \cdots \quad u[n-nb_m]u[n-m-nb_m]], \quad \forall m \in \overline{0, M-1} \\ \Phi_{yu,k}^T[n] &= [y[n-1]u[n-k-1] \quad \cdots \quad y[n-nd_k]u[n-k-nd_k]], \quad \forall k \in \overline{0, K-1}, \forall n \in \mathbb{N}. \end{aligned} \right. \quad (2.14)$$

De asemenea, prin convenție, orice valoare a vreunui semnal cu  $n < 1$  este considerată nulă.

În continuare, această structurare completă a vectorului  $\Phi[n]$  permite reformularea modelului într-o manieră extrem de versatilă, nu doar pentru estimarea parametrilor, ci și pentru implementarea practică în simulări. Mai exact, modelul NARX poate fi rescris într-o formă echivalentă, bazată pe filtre raționale, având aceiași poli ca și polinomul  $A$ . În această formulare, ieșirea sistemului este exprimată ca suma dintre o componentă utilă,  $y_u$ , și o componentă de zgomot colorat,  $v$ :

$$y[n] = y_u[n] + v[n], \quad \forall n \in \mathbb{N}. \quad (2.15)$$

Componenta utilă  $y_u$  este obținută prin aplicarea unei multitudini de filtre asupra semnalele întârziate, astfel:

$$\begin{aligned} y_u[n] &= -\sum_{p=0}^{P-1} \frac{A_p(q^{-1})}{A(q^{-1})} y[n]y[n-p] + \frac{B(q^{-1})}{A(q^{-1})} u[n] + \sum_{m=0}^{M-1} \frac{B_m(q^{-1})}{A(q^{-1})} u[n]u[n-m] + \\ &+ \sum_{k=0}^{K-1} \frac{D_k(q^{-1})}{A(q^{-1})} y[n]u[n-k], \quad \forall n \in \mathbb{N}, \end{aligned} \quad (2.16)$$

zgomotul colorat  $v$ , rezultat prin filtrarea zgomotului alb  $e$ , fiind dat de:

$$v[n] = \frac{1}{A(q^{-1})} e[n], \quad \forall n \in \mathbb{N}. \quad (2.17)$$

Această formulare este extrem de practică în contextul simulării post-identificare, permițând o implementare clar structurată, în care contribuțiile semnalelor utile și ale zgomotului sunt procesate separat. În Figura 2.1, această separare conceptuală se reflectă într-o arhitectură logică alcătuită din două părți: **NARX-IN**, unde sunt generate și filtrate combinațiile neliniare ale semnalelor de intrare și **NARX-OUT**, unde are loc generarea ieșirii.

## 2.2.2 Extindere la modele MISO-NARX

Când complexitatea sistemului crește, iar mai multe comenzi acționează simultan asupra uneia sau mai multor ieșiri, este necesară adoptarea unei arhitecturi bazate pe modele MISO-NARX, care permite captarea interacțiunilor neliniare dintre mai multe canale de intrare și mai multe ieșiri simultan.

În cazul particular al instalației ASTANK2, care dispune de două comenzi independente (tensiunile aplicate electrovalvelor de alimentare cu lichid) și două ieșiri (nivelurile de lichid din cele două rezervoare), sistemul analizat este, în esență, unul de tip MIMO. Cu toate acestea, pentru a facilita analiza detaliată și comparabilă a influenței fiecărei comenzi asupra fiecărei ieșiri, s-a optat pentru fragmentarea modelului în două sub-sisteme MISO-NARX.




Figura 2.1 Structura bloc a modelului SISO-NARX.

Fiecare sub-sistem este astfel descris printr-o ecuație proprie, care păstrează structura conceptuală a modelului SISO-NARX, dar este extinsă pentru a integra interacțiunile dintre mai multe intrări asupra unei singure ieșiri. Această abordare echilibrează interpretabilitatea matematică cu fidelitatea modelării sistemului real.

Modelul matematic rezultat pentru cele două ecuații MISO-NARX, adaptate din structura propusă în [SCVV-2024], este prezentat în ecuațiile (2.18)–(2.20) care urmează.

Pentru a adapta modelul la cazul multivariabil, notarea polinoamelor din ecuațiile (2.18) și (2.19) urmează aceeași structură ca în relațiile anterioare, însă indicii sunt particularizați pentru fiecare ieșire și combinație de semnale. Astfel, ceea ce anterior era un set unic de indici –  $P, M, K$  – devine acum o familie de seturi asociate fiecărui canal:  $\{P_1, P_2\}, \{M_{1,1}, M_{1,2}, M_{2,1}, M_{2,2}\}, \{K_{11}, K_{12}, K_{21}, K_{22}\}$ .

Această extensie adăugată, deși necesară pentru a reflecta fidel structura sistemului, aduce cu sine un număr considerabil mai mare de parametri. În consecință, sarcina de identificare devine mai solicitantă atât din punct de vedere computațional, cât și al cantității de date necesare pentru o estimare robustă.

O observație importantă este aceea că modelul presupune, în forma sa standard, că zgomotele aditive de pe diferite ieșiri nu sunt corelate. Dacă această ipoteză nu se menține, trebuie luate în calcul corelații suplimentare între zgomote, ceea ce extinde dramatic spațiul parametrilor și poate compromite simplitatea identificării.

În cele din urmă, modelul multivariabil rezultat poate fi exprimat în două forme echivalente: fie ca model de regresie (de tip (2.12)), fie într-o structură bazată pe blocuri cu filtre (precum în (2.16)). În această ultimă variantă, fiecare componentă este trecută printr-un set de filtre care reflectă arhitectura NARX. O schemă ilustrativă pentru această organizare este prezentată în Figura 2.2.

Deși elementele componente din structura generală a modelului ilustrat în Figura 2.2 au aceeași construcție ca și cea prezentată în Figura 2.1, există o diferență

importantă: în această configurație, blocurile de tip **NARX-OUT** nu mai includ filtrele ARMA, ci primesc direct zgomot alb, fără prelucrare suplimentară.

$$\left\{ \begin{aligned} & A_1(q^{-1})y_1[n] + \sum_{p=0}^{P_1-1} A_{1,p}(q^{-1})y_1[n]y_1[n-p] = \\ & = B_{1,1}(q^{-1})u_1[n] + \sum_{m=0}^{M_{1,1}-1} B_{1,1,m}(q^{-1})u_1[n]u_1[n-m] + \sum_{k=0}^{K_{1,1}-1} D_{1,1,k}(q^{-1})y_1[n]u_1[n-k] + \\ & + B_{1,2}(q^{-1})u_2[n] + \sum_{m=0}^{M_{1,2}-1} B_{1,2,m}(q^{-1})u_2[n]u_2[n-m] + \\ & + \sum_{k=0}^{K_{1,2}-1} D_{1,2,k}(q^{-1})y_1[n]u_2[n-k] + e_1[n] \\ & E\{e_1[n]e_1[m]\} = \lambda_1^2 \delta[n-m], \quad \forall n, m \in \mathbb{N}; \end{aligned} \right. \quad (2.18)$$

$$\left\{ \begin{aligned} & A_2(q^{-1})y_2[n] + \sum_{p=0}^{P_2-1} A_{2,p}(q^{-1})y_2[n]y_2[n-p] = \\ & = B_{2,1}(q^{-1})u_1[n] + \sum_{m=0}^{M_{2,1}-1} B_{2,1,m}(q^{-1})u_1[n]u_1[n-m] + \sum_{k=0}^{K_{2,1}-1} D_{2,1,k}(q^{-1})y_2[n]u_1[n-k] + \\ & + B_{2,2}(q^{-1})u_2[n] + \sum_{m=0}^{M_{2,2}-1} B_{2,2,m}(q^{-1})u_2[n]u_2[n-m] + \\ & + \sum_{k=0}^{K_{2,2}-1} D_{2,2,k}(q^{-1})y_2[n]u_2[n-k] + e_2[n] \\ & E\{e_2[n]e_2[m]\} = \lambda_2^2 \delta[n-m], \quad \forall n, m \in \mathbb{N}; \end{aligned} \right. \quad (2.19)$$

$$E\{e_1[n]e_2[m]\} = 0, \quad \forall n, m \in \mathbb{N}. \quad (2.20)$$

Merită menționat că o alternativă de implementare – mai simplă din punct de vedere numeric și mai flexibilă în privința condițiilor inițiale – este cea bazată pe forma de regresie liniară a modelului, exprimată prin ecuațiile (2.12)–(2.14). Această variantă permite rezolvarea directă a ecuației modelului, fără construirea explicită a blocurilor filtrante și este abordarea adoptată și în cadrul prezentei lucrări de licență.

În mod similar cu cazul modelului ARX, pentru a crește acuratețea descrierii zgomotului, acesta poate fi identificat ulterior prin utilizarea unor modele ARMA corespunzătoare, conform relațiilor (2.7) și (2.8).

### 2.2.3 Avantaje, limitări și utilizări ale modelelor MISO-NARX

Modelele MISO-NARX oferă un cadru flexibil și expresiv pentru identificarea sistemelor dinamice în care mai multe semnale de intrare influențează o ieșire comună. În comparație cu modelele liniare clasice, cum ar fi ARX, structura NARX permite integrarea relațiilor neliniare și a interacțiunilor complexe între regresori, prin includerea produselor între semnalele întârziate. Această formulare este deosebit de valoroasă în aplicații unde dinamica nu poate fi aproximată suficient prin termeni liniari.

O primă categorie de avantaje derivă din expresivitatea matematică: modelul MISO-NARX este capabil să surprindă efecte de cuplaj între variabilele de intrare, variații neliniare în timp și influențe combinate ale întârzierilor. Datorită acestui cadru polinomial extins, se pot reprezenta comportamente de ordin superior într-un mod

interpretabil, evitând opacitatea specifică rețelelor neuronale sau altor metode de tip "cutie neagră" (*black box*) [SCVV-2024].




Figura 2.2 Schema funcțională a modelului 2-MISO-NARX, utilizat pentru identificarea instalației ASTANK2.

În plus, separarea semnalelor de intrare prin termeni expliciți permite o analiză modulară a influenței fiecărei comenzi asupra evoluției ieșirii. În sistemele unde controlul precis al unei ieșiri depinde de mai multe surse, această caracteristică ajută atât la calibrare, cât și la diagnosticarea comportamentelor anormale.

Totuși, modelul MISO-NARX are și limitări, în special legate de volumul mare de parametri care trebuie estimați atunci când gradul polinomului sau orizonturile de întârziere cresc. Această creștere poate duce la probleme de supra-ajustare, mai ales în contexte cu zgomot ridicat sau date insuficiente. În plus, presupunerea că structura neliniară aleasă este capabilă să redea toate caracteristicile sistemului real rămâne o provocare, necesitând adesea o etapă prealabilă de analiză și selecție a regresorilor relevanți.

În cadrul instalației ASTANK2, modelul MIMO format din două comenzi independente (tensiunile aplicate electrovalvelor) și cele două ieșiri (nivelurile din rezervoare) a fost fragmentat, așa cum s-a menționat și anterior, în două sub-sisteme MISO, fiecare modelând influența celor două comenzi asupra unei singure ieșiri. Această alegere permite o analiză comparativă între modelele 2-MISO-ARX și 2-MISO-NARX, păstrând interpretabilitatea și eficiența numerică, dar extinzând capacitatea de modelare la realitatea multivariabilă a sistemului.

Conform principiilor formulate în [SCVV-24], aplicarea modelelor de tip NARX este justificată în situații precum:

- ❖ comportamentul sistemului prezintă neliniarități locale sau globale;
- ❖ datele experimentale sunt suficiente pentru estimarea unui număr mai mare de parametri;
- ❖ se dorește captarea interacțiunilor între mai mulți factori exogeni fără pierderea interpretabilității.

Astfel, în cazul ASTANK2, unde al doilea rezervor are un comportament predominant liniar, iar primul introduce o componentă neliniară, utilizarea unei structuri 2-MISO-NARX devine o alegere naturală. Aceasta permite o modelare diferențiată, dar coerentă, cu posibilitatea extinderii ulterioare către modele MIMO complete, în funcție de obiectivul aplicației (control, simulare, diagnoză etc.).

## 2.3 Metode de identificare și validare ale modelelor

### ARX și NARX

Modelul liniar se poate identifica folosind fie MCMMP, fie Metoda Minimizării Erorii de Predicție (MMEP), care este mai precisă, așa cum este precizat și în [StCuSt-2005]. Mediul de simulare MATLAB-SIMULINK™ oferă funcția de bibliotecă **armax**, bazată pe MMEP, cu care se pot identifica, în particular, modele ARX multivariabile. Aceeași funcție permite și identificarea modelelor ARMA pentru componenta de zgomot colorat.

În ceea ce privește modelul NARX, metoda predominant utilizată pentru identificare este MCMMP Multi-Pas (MCMMP-MP). Această tehnică este descrisă pe larg în [HaKe-1999] sau în [SCVV-2024], pentru modele de tip NARMAX și se bazează pe o succesiune riguroasă de pași:

1. **Selectarea modelului auxiliar:** Se utilizează un model de tip NARX pentru estimarea componentei de zgomot alb, întrucât acesta nu include zgomotul în vectorul de regresori și permite o aplicare directă a MCMMP. Acesta a fost unul dintre motivele principale ale alegerii modelului NARX pentru lucrarea de față.
2. **Estimarea zgomotului:** Pe baza modelului auxiliar, se estimează componenta de zgomot alb, care, ulterior, va înlocui zgomotul real (nemăsurabil) din vectorii de regresori ai modelului principal NARMAX.
3. **Filtrarea multi-pas:** Se aplică filtrări repetate asupra datelor de intrare și ieșire prin intermediul unui filtru construit din polinomul estimat  $\hat{C}$ , pentru a îmbunătăți precizia estimării zgomotului alb. Filtrarea se aplică inclusiv asupra produselor dintre semnale, considerate individual.
4. **Reidentificarea modelului principal:** După fiecare pas de filtrare, modelul NARMAX principal este reidentificat folosind vectorii actualizați, până la atingerea unei valori acceptabile a erorii pătratice totale sau a unui număr maxim de iterații.

Această metodologie este preferată în cazul modelelor NARX, deoarece implementarea metodei MMEP pentru astfel de modele este extrem de laborioasă și nu este suportată direct de funcțiile MATLAB existente. Spre deosebire de modelele ARX, pentru care funcția **armax** poate fi utilizată în mod direct pentru a identifica și componenta de zgomot colorat, identificarea modelelor NARX necesită un demers elaborat bazat pe filtrare și estimări recursive.

În cadrul lucrării de față, pentru a respecta obiectivele stabilite, a fost implementată această strategie multi-pas, sub coordonarea îndrumătorilor, cu o adaptare specială pentru structura de tip NARX, care, pentru mai multă simplitate, renunță la filtrările succesive din procedura de mai sus. Zgomotele colorate au fost

identificate ulterior prin funcția **armax**, similar cu modul de abordare din cazul modelelor liniare de tip ARX.

Validarea modelelor identificate (fie de tip ARX, fie de tip NARX) se desfășoară, în mod tradițional, prin intermediul simulării acestor modele atunci când sunt stimulate cu alte intrări decât cele folosite în faza de identificare. De regulă, atât semnalele de stimul pentru identificare, cât și cele pentru validare fac parte din categoria celor pseudo-aleatoare (Semnale Pseudo-Aleatoare – SPA, nu neapărat binare). Cele două semnale de stimul trebuie să fie diferite în faza de validare față de faza de identificare (pe fiecare canal de intrare în parte), dar nu pot diferi foarte mult ca medie și deviație standard, pentru a nu compromite validarea efectivă a modelului de identificare. Aceasta limitează generalitatea modelelor de identificare la o anumită colecție de puncte nominale de funcționare asociate sistemului identificat, de regulă învecinate, de cele mai multe ori, fără a putea acoperi întreaga gamă de regimuri de funcționare.

În domeniul Identificării Sistemelor, validarea se efectuează prin teste de albire, descrise, de exemplu, în [StCuSt-2005]. Însă aceste teste au o componentă empirică, ce conduce la o anumită incertitudine privind validarea sau invalidarea efectivă a modelului de identificare testat. De aceea, în cadrul acestei lucrări, s-a preferat adoptarea unei strategii sistematice de validare, în conjuncție cu identificarea. Strategia este descrisă în secțiunea următoare.

## 2.4 Determinarea indicilor structurali optimali ai modelelor

Un aspect important în faza de identificare a modelelor ARX și/sau NARX îl constituie selectarea indicilor structurali ai acestora. Pentru ambele tipuri de modele, numărul acestor indici este destul de mare (sensibil mai mare în cazul modelului NARX decât în cazul modelului ARX). Se dorește nu doar găsirea unei combinații satisfăcătoare de indici structurali, ci determinarea unei combinații optimale a acestor coeficienți. Aceasta incumbă definirea unui criteriu de optimizare dedicat, numit *concordanță* sau *potrivire* (*fitness*).

În procesul de identificare a parametrilor unui model 2-MISO-NARX utilizând metoda MCMMP-MP, este necesară stabilirea unui număr semnificativ de indici structurali. Conform relațiilor (2.18) și (2.19), se disting zece indici majori, la care se adaugă și indicii minori ce sporesc substanțial procesul de identificare și conduc către o complexitate considerabilă, mai ales dacă includem și parametrii structurali aferenți modelelor ARMA.

Această sarcină de configurare structurală trebuie abordată astfel încât modelul final să obțină performanțe bune pe ambele canale, iar rezultatele sale să poată fi validate corespunzător. Totuși, căutarea completă a celor mai potriviți indici devine rapid greu de pus în practică din punct de vedere computațional, chiar și în condițiile în care limitele superioare impuse sunt relativ restrictive. În acest context, metodele metaeuristice oferă o alternativă viabilă, permițând explorarea eficientă a acestui spațiu complex de soluții, cu un echilibru optim între acuratețea rezultatelor și cuantumul resurselor de calcul.

Metaeuristicile, așa cum se specifică și în [SBPFE-2014], au evoluat semnificativ în ultimele decenii, devenind instrumente esențiale în rezolvarea problemelor complexe de optimizare din diverse domenii ingineresti și științifice. Printre aceste metode, algoritmul *Grey Wolf Optimizer* (GWO) a câștigat popularitate datorită eficienței sale și a accesibilității implementării, inclusiv în medii de programare precum MATLAB-SIMULINK™. În comparație cu alți algoritmi consacrați, cum ar fi cei genetici, GWO se distinge printr-o structură algoritmică mai clară și un proces de configurare mai prietenos, ceea ce îl face atractiv pentru aplicații practice.

Înainte de a începe discuția despre algoritmul GWO, este necesară stabilirea unui criteriu care să poată ghida procesul de optimizare. Un indicator relevant în acest



sens este raportul semnal-zgomot (SNR – *Signal-to-Noise Ratio*), utilizat frecvent pentru a evalua calitatea unui semnal corupt de un zgomot stocastic.

Presupunând că semnalul observat  $y$  este afectat de un zgomot aditiv de medie nulă și varianță  $\lambda^2$ , parametrul SNR reflectă proporția dintre informația utilă (semnalul propriu-zis) și perturbațiile nedorite (zgomotul), din punctul de vedere al dispersiei în jurul mediei (adică al deviației standard). Așadar, pentru a-l calcula, se consideră deviația standard a semnalului  $y$ , raportată la deviația standard a zgomotului. Dacă  $\bar{y}$  este valoarea medie a semnalului, atunci semnalul centrat se definește ca  $\tilde{y} = y - \bar{y}$ , iar deviația standard a semnalului devine:

$$\sigma_y = \sqrt{E\{\tilde{y}^2\}} = \sqrt{E\{(y - \bar{y})^2\}}. \quad (2.21)$$

Astfel, SNR poate fi exprimat ca:

$$\text{SNR} = \frac{\sigma_y}{\lambda} = \frac{\sqrt{E\{\tilde{y}^2\}}}{\lambda} = \frac{\sqrt{E\{(y - \bar{y})^2\}}}{\lambda}. \quad (2.22)$$

În situația în care semnalul conține  $N$  eșantioane și varianța zgomotului  $\lambda^2$  este estimată printr-un model de identificare, se poate utiliza Ipoteza Ergodică pentru a aproxima SNR. Astfel, formula (2.22) devine:

$$\hat{\text{SNR}} = \frac{\sqrt{\frac{1}{N} \sum_{n=1}^N \tilde{y}^2[n]}}{\hat{\lambda}_N}, \quad (2.23)$$

unde  $\hat{\lambda}_N^2$  reprezintă dispersia estimată a zgomotului (considerat de medie nulă), iar semnalul  $\tilde{y}$  este obținut prin centrarea pe media sa:

$$\tilde{y}[n] = y[n] - \frac{1}{N} \sum_{n=1}^N y[n], \quad \forall n \in \overline{1, N}. \quad (2.24)$$

În mod uzual, SNR este exprimat în decibeli (dB). Atunci când se utilizează un set de date de identificare de tip intrare-ieșire  $\mathbf{D}_N = \{u[n], y[n]\}_{n \in \overline{1, N}}$ , estimarea SNR se poate realiza pe baza relațiilor (2.23) și (2.24), folosind următoarea formulă:

$$\hat{\text{SNR}} = \frac{\sqrt{\sum_{n=1}^N \tilde{y}^2[n]}}{\sqrt{\sum_{n=1}^N (y[n] - \hat{y}_u[n])^2}} = \frac{\sqrt{\sum_{n=1}^N \tilde{y}^2[n]}}{\sqrt{\sum_{n=1}^N (y[n] - \boldsymbol{\varphi}_{u,y}^T[n] \hat{\boldsymbol{\theta}}_{N,u,y})^2}} \quad (2.25)$$

Este important de subliniat că, în relația (2.25), zgomotul nu este măsurat direct, ci estimat pe baza ieșirii simulate a componentei utile din structura modelului, calculată cu ajutorul parametrilor obținuți în urma procesului de identificare. Această abordare este valabilă pentru toate tipurile de modele discutate anterior, inclusiv MISO-ARX, MISO-NARX și SISO-ARMA.

Totuși, în cazul particular al modelelor SISO-ARMA, raportul SNR se referă explicit la zgomotul alb, considerat a fi unicul tip de semnal rezidual. În schimb, modelele MISO implică de obicei zgomote colorate, care nu pot fi tratate direct ca zgomot alb, ci mai degrabă ca semnale parazite ce trebuie filtrate sau modelate.

Pentru aceste situații, mediul de programare MATLAB™ pune la dispoziție funcția **pe** (*prediction error*), care permite estimarea componentei de zgomot alb pe baza zgomotului colorat și a modelului ARMA identificat. Astfel, varianța zgomotului alb



$\hat{\lambda}_N^2$  poate fi determinată cu ușurință, oferind automat o soluție robustă pentru determinarea raportului SNR.

Un model bine identificat ar trebui să genereze valori cât mai ridicate ale SNR, reflectând o bună separare între semnalul util și zgomot. Deoarece nu există o limită superioară universală pentru acest raport, se poate recurge la o funcție de normalizare, care să limiteze variația SNR în cadrul unui interval finit. O astfel de funcție este, de exemplu cea de mai jos:

$$f(x) = \frac{1}{1+x}, \quad \forall x \in \mathbb{R}_+. \quad (2.26)$$

Relația (2.26) definește o funcție hiperbolică ce asociază bijectiv valorile pozitive reale ale raportului SNR cu valori din intervalul închis restrâns între 0 și 1. În proximitatea valorii unitare, comportamentul funcției devine aproape liniar, ceea ce o face utilă pentru normalizarea și compararea valorilor de SNR provenite din surse diferite.

Pe baza acestei funcții, se poate construi un criteriu esențial pentru evaluarea performanței, cunoscut sub denumirea de „funcție *fitness* elementară”. Acesta este definită prin relația:

$$f(\text{SNR}) = \frac{\eta}{1 + \frac{\mu}{\text{SNR}}} \in (0, \eta), \quad \forall \text{SNR} \in \mathbb{R}_+. \quad (2.27)$$

Parametrii  $\eta$  și  $\mu$  sunt controlați de utilizator și au roluri diferite. Pe de o parte, parametrul  $\eta$ , cuprins în intervalul  $[0, 1]$ , acționează ca un factor de ponderare, fiind util în situațiile în care se evaluează mai multe tipuri de SNR. În cazul în care se analizează un singur SNR, se poate alege  $\eta = 1$ , ceea ce permite funcției să genereze valori direct între 0 și 1. Pe de altă parte,  $\mu$  este un parametru de ajustare, care influențează sensibilitatea funcției *fitness*. Astfel, prin alegerea corespunzătoare a acestor doi parametri, utilizatorul poate adapta funcția de evaluare la contextul specific al problemei de optimizare.

În cazul modelelor de tip 2-MISO (ARX sau NARX), fiecare canal de ieșire impune evaluarea separată a performanței predicției. Din acest motiv, se calculează două valori ale SNR, câte una pentru fiecare ieșire, conform relației (2.25).

Pentru a evalua în mod riguros capacitatea de generalizare a modelului identificat, setul de date disponibil este împărțit în două submulțimi distincte: unul destinat procesului de identificare  $\mathbf{D}_{N_{id}}^{id}$ , iar celălalt utilizat pentru validare  $\mathbf{D}_{N_{va}}^{va}$ . Aceste submulțimi pot avea lungimi diferite ( $N_{id}$ , respectiv  $N_{va}$ ), iar modelul antrenat pe prima submulțime este testat folosind intrările din al doilea, comparând răspunsurile simulate cu cele observate în practică.

Pentru a integra în mod echilibrat performanța modelului pe ambele submulțimi și pe fiecare canal de ieșire, se definește un vector de evaluare cu patru componente, corespunzând combinațiilor {ieșire, submulțime}. Fiecare componentă este exprimată printr-o funcție *fitness* elementară, derivată din relația (2.27), care normalizează valorile SNR în intervalul  $[0, 1]$ , oferind astfel o scală comună de comparație.

Fiecare valoare de *fitness* este ponderată cu un coeficient corespunzător subsetului din care provine –  $\eta_{id}$  pentru identificare și  $\eta_{va}$  pentru validare – proporțional cu dimensiunea acestuia. Pentru a păstra consistența metricii, acești coeficienți sunt normalizați astfel încât suma pătratelor lor să fie egală cu 1. Se obține astfel următoarea formulare:

$$\mathbf{f} = \frac{1}{\sqrt{2(\eta_{id}^2 + \eta_{va}^2)}} \begin{bmatrix} \frac{\eta_{id}}{1 + \frac{1}{\text{SNR}_{id_1}}} & \frac{\eta_{id}}{1 + \frac{1}{\text{SNR}_{id_2}}} & \frac{\eta_{va}}{1 + \frac{1}{\text{SNR}_{va_1}}} & \frac{\eta_{va}}{1 + \frac{1}{\text{SNR}_{va_2}}} \end{bmatrix}. \quad (2.28)$$

Astfel construit, vectorul de evaluare (2.28) capătă un rol central în procesul de optimizare. Însă, pentru a asigura comparabilitatea între modele și robustețe în evaluare, este necesar un pas suplimentar: scalarea automată a ponderilor aferente celor două subseturi.

Pentru aceasta, coeficienții de ponderare  $\eta_{id}$  și  $\eta_{va}$  sunt calculați direct din dimensiunile seturilor de identificare și validare, după relațiile:

$$\eta_{id} = \frac{N_{id}}{2(N_{id} + N_{va})}, \quad \eta_{va} = \frac{N_{va}}{2(N_{id} + N_{va})}. \quad (2.29)$$

Datorită modului în care sunt definiți coeficienții, suma lor de-a lungul vectorului  $\mathbf{f}$  este egală cu 1. Mai mult, factorul de normalizare din definiția (2.28) obligă norma euclidiană a vectorului  $\mathbf{f}$  să nu depășească valoarea 1. Acest aspect este esențial, deoarece permite comparabilitatea între modele, indiferent de dimensiunea absolută a submulțimilor utilizate.

În situația particulară în care dimensiunile subseturilor de identificare și validare sunt egale, adică  $N_{id} = N_{va}$ , rezultă că ambii coeficienți de ponderare devin egali  $\eta_{id} = \eta_{va} = 0.25$ . În acest caz, factorul de normalizare  $\sqrt{2(\eta_{id}^2 + \eta_{va}^2)}$  din definiția (2.28) este egal cu 1/2. Această proprietate conferă stabilitate formalismului de evaluare și permite integrarea ulterioară a vectorului  $\mathbf{f}$  într-o funcție de *fitness* globală, fără a necesita ajustări suplimentare pentru scalare.

Pornind de la aceste premize, se construiește funcția *fitness* globală, utilizată pentru identificarea configurației structurale optime. Această funcție ține cont atât de dispersia internă a valorilor din vectorul de evaluare, cât și de amplitudinea globală a acestora. Formula sa generală este:

$$F = 50 \left( \frac{1}{1 + \mu\sigma_r} + \frac{1}{1 + \frac{\mu}{\|\mathbf{f}\|}} \right) \in (0, 100]\% \quad (2.30)$$

În definiția (2.30):

- $\sigma_r$  reprezintă deviația standard a celor patru componente din vectorul  $\mathbf{f}$ , oferind o măsură a dispersiei interne a lor în jurul mediei;
- $\|\mathbf{f}\|$  este norma sa euclidiană, asociată intensității generale a performanței;
- $\mu$  este parametrul ajustabil utilizat pentru a regla sensibilitatea funcției la diferențele dintre componente.

Deviația standard  $\sigma_r$  și media aritmetică  $\mu_r$  a celor patru componente sunt definite prin relațiile:

$$\sigma_r = \frac{1}{2} \sqrt{\sum_{i=1}^4 (\mathbf{f}[i] - \mu_r)^2}, \quad \mu_r = \frac{1}{4} \sum_{i=1}^4 \mathbf{f}[i]. \quad (2.31)$$

Formula (2.31) este construită astfel încât să penalizeze dezechilibrele din structura internă a vectorului de *fitness*: cu cât dispersia valorilor componente (măsurată prin deviația standard) este mai mare, cu atât scorul total este mai mic. În schimb, un vector cu o normă mare – care reflectă o performanță globală bună – conduce la o valoare mai mare a funcției de fitness (având în vedere că toate

elementele vectorului  $\mathbf{f}$  sunt pozitive și subunitare, iar norma vectorului este cel mult egală cu 1). Această abordare asigură o echilibrare a scorului final, atât între cele două canale de ieșire, cât și între seturile de date pentru identificare și validare.

Prin urmare, este foarte puțin probabil ca un model să obțină un scor ridicat dacă performează excepțional pe un singur canal sau doar pe un subset de date, dar necorespunzător pe celelalte. Formula este concepută tocmai pentru a evita astfel de dezechilibre, solicitând consistență pe toate componentele.

Pentru modelele de tip SISO-ARMA, unde există un singur canal de ieșire, vectorul de *fitness* se simplifică la două componente, corespunzătoare subseturilor de identificare și validare. Forma sa este următoarea:

$$\mathbf{f} = \frac{1}{\sqrt{\eta_{id}^2 + \eta_{va}^2}} \begin{bmatrix} \frac{\eta_{id}}{1 + \frac{1}{\text{SNR}_{id}}} & \frac{\eta_{va}}{1 + \frac{1}{\text{SNR}_{va}}} \end{bmatrix}, \quad (2.32)$$

unde coeficienții de ponderare sunt calculați astfel încât să reflecte proporția fiecărui subset în totalul datelor utilizate:

$$\eta_{id} = \frac{N_{id}}{N_{id} + N_{va}}, \quad \eta_{va} = \frac{N_{va}}{N_{id} + N_{va}}. \quad (2.33)$$

Această formulare păstrează logica echilibrului și a scalării proporționale, chiar și în cazul unui singur canal de ieșire, oferind o metrică coerentă pentru evaluarea performanței modelului.

Prin maximizarea valorilor de *fitness*, se pot determina indicii structurali optimali. De notat că optimizarea se desfășoară în doi pași succesivi. Mai întâi, se identifică modelul util optimal, de tip ARX sau NARX. După ce acesta a fost identificat, se identifică modelul de zgomot optimal, de tip ARMA. Prin urmare, metaeuristica trebuie utilizată în două etape distincte, una după cealaltă. În cazul modelului de tip NARX, identificarea acestuia presupune o utilizare ierarhizată a metaeuristicii: la nivel superior, pentru determinarea indicilor majori și la nivel inferior, pentru determinarea indicilor minori corespunzători celor majori determinați.

## 2.5 Algoritmul Grey Wolf Optimizer (GWO)

### 2.5.1 Privire generală asupra metaeuristicilor

În cadrul problemelor de optimizare moderne, metodele clasice deterministe devin adesea ineficiente atunci când sunt aplicate pe funcții neliniare, multidimensionale sau discontinue. În acest context, metaeuristicile au apărut ca o alternativă robustă, flexibilă și eficientă pentru identificarea soluțiilor optime sau aproape optime, în special atunci când informațiile despre problemă sunt incomplete sau greu de formulat analitic.

Etimologic, termenul „euristică” provine din grecescul *heuriskein*, care înseamnă „a descoperi”, „a afla”, „a găsi dintr-o privire”. Extensia sa, „metaeuristică”, desemnează o clasă de strategii de căutare generalizate, capabile să ghideze procesul de explorare a spațiului de soluții prin reguli inspirate din natură, comportament colectiv sau mecanisme evolutive după cum se menționează în [SBPFE-2014].

Pentru a ilustra diferența față de o căutare exhaustivă, voi apela la o analogie similară cu cea prezentată în [SBPFE-2014]: să presupunem că un detectiv încearcă să rezolve un caz. O abordare ar fi să verifice sistematic fiecare variantă posibilă – ceea ce, deși sigur, consumă un timp uriaș. Alternativa – specifică metaeuristicilor – este să urmeze o pistă plauzibilă și, pe baza indicilor acumulate, să își ajusteze direcția investigației în mod adaptiv. Aceasta este căutarea inteligentă, ghidată, care

poate ajunge rapid la un rezultat acceptabil, chiar dacă nu este garantat că alt rezultat mai bun nu există.

Metaeuristicile se disting prin faptul că nu sunt legate de o formulare matematică strictă a problemei și nu depind de derivabilitate sau convexități, ceea ce le face potrivite pentru o gamă largă de aplicații ingineresti. Este adevărat, pentru ele nici nu există rezultate matematice riguroase de convergență. (Anumite metaeuristici, cum ar fi Algoritmii Genetici, beneficiază de anumite rezultate parțiale de convergență și de o serie de conjecturi.) Această deficiență plasează metaeuristicile la frontiera dintre știință și abordare empirică. Cu toate acestea, metaeuristicile au rezolvat cu succes numeroase probleme de optimizare complicate, în care intervin numeroase variabile de decizie, iar spațiul de căutare este nu doar lipsit de proprietăți de convexitate, ci și fluid (fără frontiere clare). Exemple notabile includ Algoritmii Genetici, Optimizarea prin Roiuri de Particule, Algoritmul Liliilor, Algoritmul Licuricilor, Algoritmul Coloniei de Furnici, Algoritmul Roiului de Albine, Algoritmul de Căutare al Cucului și mulți alții, care au fost și sunt încă în proiectare. În această lucrare, va fi prezentată metaeuristica numită *Grey Wolf Optimizer* (GWO).

### 2.5.2 Principiul metaeuristicii GWO

Algoritmul GWO, propus de Seyedali Mirjalili et. al. în [Mir-2014], este o tehnică metaeuristică de optimizare inspirată din comportamentul social și strategia de vânătoare a lupilor cenușii (*Canis Lupus*). Acest algoritm aparține clasei metaeuristicilor bazate pe inteligența de grup (*Swarm Intelligence*) și se remarcă printr-un echilibru eficient între fazele de explorare și exploatare, precum și printr-un număr redus de parametri de ajustat, după cum menționează și autorul.

Metaeuristica din cadrul algoritmului GWO simulează două aspecte esențiale din viața lupilor: ierarhia socială strictă și dinamica vânătorii în haită. Ierarhia este reprezentată prin patru tipuri de indivizi:

- $\alpha$  (**alpha**) – liderul haitei, responsabil cu luarea deciziilor strategice;
- $\beta$  (**beta**) – asistentul liderului, menține disciplina și comunicarea în haită;
- $\delta$  (**delta**) – include lupi subordonați, precum cercetași, vânători sau gardieni;
- $\omega$  (**omega**) – cei mai slabi membri, care joacă rolul de supape sociale și stabilizatori ai grupului.

Pe lângă structura ierarhică, GWO modelează comportamentul de vânătoare al lupilor, care se desfășoară în trei etape:

1. **Detectarea și urmărirea prăzii.** Membrii haitei identifică prada de la distanță și o urmăresc organizat.
2. **Înconjurarea prăzii.** Lupii se poziționează strategic pentru a restrânge spațiul de manevră al victimei.
3. **Atacul coordonat.** Liderii inițiază atacul, iar ceilalți membri intervin pentru a finaliza prinderea.

Aceste faze sunt transpuse în algoritm printr-un set de mecanisme matematice care guvernează modul în care agenții își actualizează pozițiile în spațiul de căutare, astfel încât să reflecte cât se poate de fidel dinamica colectivă a haitei.

### 2.5.3 Modelul matematic al metaeuristicii GWO

Modelarea matematică a algoritmului GWO se bazează, așa cum a fost menționat și anterior, pe structura ierarhică a haitei de lupi și pe modul coordonat în care aceștia desfășoară o vânătoare. În analogia algoritmică, cele mai bune trei soluții din populație, notate cu  $X_\alpha$ ,  $X_\beta$  și  $X_\delta$ , sunt considerate cele mai bune aproximări ale poziției prăzii (adică a soluției optime). Restul agenților, asociați rolului de  $\omega$ , își vor

ajusta pozițiile, ghidându-se după aceste trei repere. Algoritmul se bazează pe ecuații matematice ce descriu strategia de căutare a optimului în cadrul a trei etape succesive. Pentru a le descrie, vom considera că haita include  $L$  lupi, fiecare dintre ei având indexul  $l$ .

### 2.5.3.1 Etapa de detectare a prăzii

Pentru a descrie matematic comportamentul de detectare a prăzii, se consideră că fiecare lup (informatic)  $l \in \overline{1, L}$  se repositionează în funcție de o pradă curentă ipotetică, localizată în poziția  $\vec{X}_p[k]$  (unde  $k \geq 0$  este indicele de iterație curent). Această mișcare este definită de ecuațiile următoare (adaptate după [Mir-2014]):

$$\vec{D}_l[k] = \vec{C}_l[k] * \vec{X}_p[k] - \vec{X}_l[k], \quad (2.34)$$

$$\vec{X}_l[k+1] = \vec{X}_p[k] - \vec{A}_l[k] * \vec{D}_l[k], \quad (2.35)$$

unde:

- $\vec{X}_l[k]$  reprezintă poziția curentă a lupului;
- $\vec{X}_l[k+1]$  reprezintă poziția posibilă următoare a lupului;
- $*$  desemnează produsul dintre doi vectori la nivel de element;
- $\vec{D}_l[k]$  este vectorul de distanțe relative ipotetice dintre lup și pradă, calculate pentru fiecare dintre componentele vectorilor de poziție;
- $\vec{A}_l[k]$  și  $\vec{C}_l[k]$  sunt vectori curenți de control, calculați astfel (pentru fiecare lup):

$$\vec{A}_l[k] = a[k](2 \cdot \vec{r}_{l,1}[k] - 1); \quad \vec{C}_l[k] = 2 \cdot \vec{r}_2[k]. \quad (2.36)$$

Parametrul scalar  $a$  din ecuația (2.36) este același pentru întreaga haită de lupi și scade liniar de la 2 la 0, pe parcursul iterațiilor, după formula:

$$a[k] = 2 \left( 1 - \frac{k}{K} \right), \quad \forall k \in \overline{0, K}, \quad (2.37)$$

unde  $K$  este numărul maxim de iterații impus de utilizator, iar  $\vec{r}_1[k]$  și  $\vec{r}_2[k]$  sunt vectori pseudo-aleatori cu componente distribuite uniform în intervalul  $[0, 1]$ .

De notat, totuși, că poziția prăzii,  $\vec{X}_p[k]$ , nu este cunoscută cu exactitate, ci doar bănuită („detectată”). În implementare, poziția prăzii,  $\vec{X}_p[k]$ , poate fi oricare dintre cele mai bune trei soluții curente  $\vec{X}_\alpha[k]$  (a liderului  $\alpha$ ),  $\vec{X}_\beta[k]$  (a asistentului  $\beta$ ) și  $\vec{X}_\delta[k]$  (a celui mai bun subordonat  $\delta$ ), din punctul de vedere al funcției-cost utilizate, calculate pe ansamblul pozițiilor lupilor din haită. Practic, lupul  $l \in \overline{1, L}$  este atras în trei direcții, dacă nu ocupă chiar el una dintre pozițiile  $\vec{X}_\alpha[k]$ ,  $\vec{X}_\beta[k]$  sau  $\vec{X}_\delta[k]$ , caz în care este tentat să testeze și celelalte două poziții. Oricum, el a detectat că există o pradă.

### 2.5.3.2 Etapa de înconjurare a prăzii

Având în vedere că poziția exactă a prăzii,  $\vec{X}_p[k]$ , nu este cunoscută în mod direct, algoritmul presupune că aceasta poate fi estimată prin combinarea celor mai bune trei soluții descoperite până la acel moment. Astfel, pozițiile curente cu cele mai

bune trei valori ale funcției-cost, adică  $\vec{X}_\alpha[k]$ ,  $\vec{X}_\beta[k]$  și  $\vec{X}_\delta[k]$ , sunt utilizate pentru a ghida procesul de actualizare a pozițiilor lupilor din haită.

Pentru fiecare lup  $l \in \overline{1, L}$ , se calculează vectorii de distanțe față de cele trei poziții lider (posibile prăzi) :

$$\begin{cases} \vec{D}_{l,\alpha}[k] = \vec{C}_{l,\alpha}[k] * \vec{X}_\alpha[k] - \vec{X}_l[k] \\ \vec{D}_{l,\beta}[k] = \vec{C}_{l,\beta}[k] * \vec{X}_\beta[k] - \vec{X}_l[k] , \\ \vec{D}_{l,\delta}[k] = \vec{C}_{l,\delta}[k] * \vec{X}_\delta[k] - \vec{X}_l[k] \end{cases} \quad (2.38)$$

unde vectorii  $\vec{C}_{l,\alpha}[k]$ ,  $\vec{C}_{l,\beta}[k]$  și  $\vec{C}_{l,\delta}[k]$  se generează pseudo-aleator, ca în ecuațiile (2.36) și (2.37).

Pe baza vectorilor de distanțe (2.38), se obțin trei poziții intermediare, următoare, posibile, ale lupului:

$$\begin{cases} \vec{X}_{l,\alpha}[k+1] = \vec{X}_\alpha[k] - \vec{A}_{l,\alpha}[k] * \vec{D}_{l,\alpha}[k] \\ \vec{X}_{l,\beta}[k+1] = \vec{X}_\beta[k] - \vec{A}_{l,\beta}[k] * \vec{D}_{l,\beta}[k] , \\ \vec{X}_{l,\delta}[k+1] = \vec{X}_\delta[k] - \vec{A}_{l,\delta}[k] * \vec{D}_{l,\delta}[k] \end{cases} \quad (2.39)$$

unde vectorii  $\vec{A}_{l,\alpha}[k]$ ,  $\vec{A}_{l,\beta}[k]$  și  $\vec{A}_{l,\delta}[k]$  se generează pseudo-aleator, dar cu amplitudini descrescătoare, ca în ecuațiile (2.36) și (2.37).

Prin aceste poziționări posibile, GWO permite lupilor să simuleze mișcări circulare în jurul prăzii, cu alternarea între explorare (dacă vectorii  $\vec{A}$  au componente subunitare) și exploatare (dacă vectorii  $\vec{A}$  au componente unitare sau supraunitare). Acesta este, de fapt, mecanismul de la baza mișcărilor circulare ale lupilor în jurul prăzilor detectate.

### 2.5.3.3 Etapa de atac coordonat

Pentru iterația următoare, lupul  $l \in \overline{1, L}$  se decide să se mute în poziția medie:

$$\vec{X}_l[k+1] = \frac{\vec{X}_{l,\alpha}[k+1] + \vec{X}_{l,\beta}[k+1] + \vec{X}_{l,\delta}[k+1]}{3}, \quad (2.40)$$

pe care o presupune mai aproape de pradă. Ea poate sau nu să fie în apropierea prăzii reprezentată de punctul de optim al funcției-cost. Oricum, întreaga haită își modifică poziția, cu intenția apropierei de pradă.

După ce toți lupii din haită s-au deplasat în noile poziții, are loc alegerea liderilor  $\alpha$ ,  $\beta$  și  $\delta$ , adică reactualizarea celor mai bune 3 poziții,  $\vec{X}_\alpha[k+1]$ ,  $\vec{X}_\beta[k+1]$ , respectiv  $\vec{X}_\delta[k+1]$ . Acum, se poate trece la iterația următoare,  $k \leftarrow k+1$ .

Pe măsură ce procesul de optimizare avansează, algoritmul își reduce progresiv explorarea și se concentrează asupra regiunilor identificate ca promițătoare. În analogia cu comportamentul natural al haitei de lupi, această fază corespunde momentului în care prada este înconjurată și atacată, iar lupii își sincronizează mișcările pentru a o captura.

Din punct de vedere algoritmic, această etapă este guvernată de vectorul de control  $\vec{A}$ , ale cărui componente scad treptat (dar cu oscilații) în decursul iterațiilor.

Aceste componente influențează strategia de deplasare a fiecărui lup cum se precizează, după cum urmează:

- dacă  $\vec{A}$  are componente majoritar subunitare în modul, lupul se îndepărtează de lideri, favorizând explorarea altor regiuni din spațiul de căutare;
- dacă majoritatea componentelor lui  $\vec{A}$  sunt unitare sau supraunitare în modul, lupul este atras către lideri, favorizând exploatarea zonei locale.

Prin această variere controlată a componentelor lui  $\vec{A}$ , algoritmul realizează tranziția naturală de la o căutare largă la o concentrare intensă în jurul celor mai bune soluții. În ultimele faze ale optimizării, când componentele lui  $\vec{A}$  tind spre zero, pozițiile lupilor din haită converg către liderii  $\alpha$ ,  $\beta$  și  $\delta$ , reflectând o convergență colectivă în jurul zonei considerate optime.

Această etapă contribuie decisiv la rafinarea rezultatelor finale, simulând un atac coordonat și permițând algoritmului să investigheze în detaliu regiunea în care este localizată prada (soluția optimă estimată).

Căutarea prăzii se încheie când s-au parcurs toate iterațiile de la 1 la o valoare maximă,  $K$ , impusă de utilizator. Punctul de optim returnat este cel al liderului  $\alpha$ , adică  $\vec{X}_\alpha[K]$ , cu funcția-cost cea mai bună de până atunci.

Deși nu este garantată convergența haitei de lupi informatici către optimul global al funcției-cost, prin strategia de mai sus, este posibil ca haita să se strângă tot mai mult în jurul unui astfel de optim (local sau global). Fenomenul este similar celui din Algoritmul Roiului de Particule (deși, în acel algoritm, strategia de căutare este mai sofisticată, fapt care permite atingerea unui punct optimal cu un număr mai mic de iterații).

Această strategie reflectă (deși destul de rudimentar) modul în care, în natură, haitele de lupi colaborează pentru a identifica și intercepta prada. În algoritm, această cooperare se traduce printr-un echilibru între încrederea în liderul absolut ( $\alpha$ ) și influența contribuțiilor subluderilor ( $\beta$  și  $\delta$ ), contribuind la o direcționare relativ robustă a căutării către zona optimă din spațiul de soluții.

Astfel, „vânătoarea algoritmică” devine un proces adaptiv, în care fiecare lup informatic este atras către o zonă comună estimată ca fiind promițătoare, fără a se ancora prematur într-un unic punct de atracție.

Din perspectivă matematică, acest comportament este reglat în principal de vectorii  $\vec{A}$  și  $\vec{C}$ , ale căror componente fluctuează stocastic la fiecare iterație. Vectorul  $\vec{A}$ , prin tendința descrescătoare a lungimii sale, controlează distanța și direcția față de lideri – permițând inițial o căutare largă (când componentele lui  $\vec{A}$  sunt majoritar subunitare în modul) și, ulterior, o concentrare în jurul soluțiilor de top (când acele componente sunt majoritar, dacă nu toate, de modul cel puțin unitar). În paralel, vectorul  $\vec{C}$  introduce o variație în percepția poziției liderilor, prevenind o atracție rigidă și crescând capacitatea algoritmului de a evita capcanele locale.

Pe măsură ce iterațiile avansează, această dinamică se traduce printr-o tranziție naturală: de la un comportament exploratoriu, în care populația sondează multiple regiuni ale spațiului de soluții, către unul de exploatare, în care mișcările se concentrează tot mai mult în jurul celor mai bune poziții identificate.

Prin această abordare simplă cu puțini parametri de configurare (mărimea haitei de lupi,  $L$  și numărul maxim de iterații,  $K$ ), GWO reușește să evite atât convergența prematură, cât și rătăcirea excesivă în spațiul de căutare – două dintre cele mai frecvente deficiențe ale algoritmilor evoluționari. Cu toate acestea, alte meteoristici permit alternarea dintre explorarea și exploatare, din timp în timp, tocmai pentru a evita

atragera întregii populații de către un optim local. Este cazul, de exemplu, al Algoritmilor Genetici sau al celui bazat pe Roiul de Particule. Migrarea treptată către exploatare dinspre explorare, fără o dispersare pseudo-aleatoare a unor membri ai populației, departe de majoritatea membrilor populației, crește riscul de blocare a întregii populații într-un optim local de slabă calitate.

#### 2.5.4 Pașii principali ai algoritmului GWO

Având definite fundamentele matematice și comportamentale ale algoritmului GWO, se poate descrie succesiunea logică a pașilor de implementare. Acești pași urmează strategia de vânătoare modelată anterior și pot fi sintetizați astfel:

1. **Inițializarea haitei de lupi.** Se generează o mulțime inițială de soluții candidate  $\vec{X}_l[0]$ , unde  $l = \overline{1, L}$ , fiecare reprezentând poziția unui lup (informatic). De regulă, aceste poziții se răspândesc uniform (pe cât este posibil) în cadrul spațiului de căutare.
2. **Evaluarea funcției-cost.** Se calculează valoarea funcției-cost pentru fiecare lup din haită.
3. **Determinarea liderilor.** Se identifică cele mai bune trei soluții din populație:
  - $\vec{X}_\alpha[0]$ : cel mai performant lup (liderul  $\alpha$ );
  - $\vec{X}_\beta[0]$ : al doilea cel mai bun lup (asistentul  $\beta$ );
  - $\vec{X}_\delta[0]$ : al treilea cel mai bun lup (cel mai bun subordonat  $\delta$ ).
4. **Setarea parametrilor de control.** Mai întâi se setează  $a_0 = 2$ , conform ecuației (2.37) (pentru  $k = 0$ ). Apoi, pentru fiecare lup  $l = \overline{1, L}$  din haită, se inițializează parametrii care vor ghida procesul de optimizare:  $\vec{A}_{l,\alpha}[0]$ ,  $\vec{A}_{l,\beta}[0]$ ,  $\vec{A}_{l,\delta}[0]$ ,  $\vec{C}_{l,\alpha}[0]$ ,  $\vec{C}_{l,\beta}[0]$  și  $\vec{C}_{l,\delta}[0]$ , conform ecuației (2.36). (Acest pas, ca și cel în care parametrii se reactualizează, necesită existența unui generator pseudo-aleator uniform de numere, cum este, de exemplu, funcția **rand** din mediul de programare MATLAB-SIMULINK™.)
5. **Iterarea procesului de optimizare.** Pentru fiecare iterație  $k \in \overline{0, K-1}$ :
  - Se actualizează poziția fiecărui lup  $l = \overline{1, L}$ ,  $\vec{X}_l[k+1]$ , conform ecuațiilor (2.38)–(2.40), folosind informațiile de la lideri.
  - Se recalculează valorile funcției-cost pentru noile poziții ale lupilor.
  - Se actualizează cele mai bune 3 poziții:  $\vec{X}_\alpha[k+1]$ ,  $\vec{X}_\beta[k+1]$  și  $\vec{X}_\delta[k+1]$ .
  - Se ajustează valorile parametrilor de tip  $a$  (pentru întreaga haită), potrivit ecuației (2.37),  $\vec{A}$  și  $\vec{C}$  (pentru fiecare lup), potrivit ecuațiilor (2.36).
  - Se incrementează contorul de iterații:  $k \leftarrow k + 1$ .
6. **Rezultatul final.** După terminarea iterațiilor, se returnează poziția liderului  $\alpha$ , adică  $\vec{X}_\alpha[K]$ , drept cea mai bună soluție găsită, împreună cu valoarea funcției-cost asociate.



### 2.5.5 Avantaje și limitări ale algoritmului GWO

Algoritmul GWO se remarcă printr-o implementare intuitivă și un număr redus de parametri de configurare, ceea ce îl face ușor de aplicat în diverse contexte. Un alt punct forte îl reprezintă echilibrul relativ între explorare și exploatare, asigurat prin dinamica parametrilor vectoriali și prin modelarea comportamentului de vânătoare.

Totuși, în cazul unor probleme cu dimensionalitate ridicată sau multimodalitate pronunțată, GWO poate prezenta limitări în ceea ce privește convergența globală sau viteza de optimizare. În astfel de cazuri, se recomandă combinarea cu alte tehnici metaeuristice mai performante. Metaeuristica GWO poate servi foarte bine ca furnizor al unor inițializări pentru astfel de metaeuristici.

În final, GWO reprezintă o strategie metaeuristică robustă și elegantă, inspirată din ierarhia socială și colaborarea specifică haitei de lupi. Această metaforă naturală oferă un cadru eficient pentru explorarea vastă a spațiului de căutare, urmată de convergența adaptivă către soluții de calitate, ceea ce recomandă GWO pentru o gamă largă de probleme de optimizare globală.

Există abordări în controlul automat care apelează la algoritmul GWO, deși performanțele acestuia nu sunt deosebite. În această lucrare, el a fost preferat în special pentru faptul că este ușor de implementat și, în plus, mediul de programare MATLAB\_SIMULINK™ oferă o implementare în cadrul cutiei de instrumente [GWO](#) [GWO-2018].

## 3 Regulatorul PID multi-variabil discret

### 3.1 Regulatorul PID în timp continuu

În cadrul sistemelor monovariabile (SISO), structura clasică a unui regulator PID în timp continuu este bine cunoscută și relativ simplu de implementat. Totuși, în aplicațiile reale, mai ales în cele industriale, ne confruntăm adesea cu procese multi-variabile, în care există mai multe variabile de ieșire și/sau de intrare. Acest context impune extinderea strategiei de reglare de la cazul SISO la cazurile MISO sau MIMO așa cum s-a profilat și în secțiunile anterioare.

Astfel, regulatorul PID trebuie generalizat pentru a putea trata simultan influențele multiple între canalele de control. În particular, în cazul analizat aici – două sisteme de tip MISO ce se combină pentru a aproxima unul de tip MIMO – schema regulatorului PID se adaptează pentru a acționa asupra fiecărei intrări, ținând cont de influența acesteia asupra ieșirii comune.

Schema propusă în Figura 3.1 reprezintă o versiune extinsă a regulatorului PID, aferentă operării în timp continuu, fiind construită astfel încât să fie compatibilă cu ambele modele de identificare (ARX și NARX). De aceea, în schema prezentată, nu este precizat un model anume, ci se folosește simplu sintagma „MISO”, cu numerotarea de rigoare.




Figura 3.1 Schema control automat folosind regulatorul PID multi-dimensional

Se recunosc parametrii specifici ai regulatorului, mai precis constantele de tip  $K_p$  (pentru componenta proporțională),  $T_i$  (pentru componenta integrală), și perechea  $\{T_d, N_d\}$  (pentru componenta derivativă). Ele pot fi grupate în 4 matrici:

$$\mathbf{K}_p = \begin{bmatrix} K_{p,11} & K_{p,12} \\ K_{p,21} & K_{p,22} \end{bmatrix}, \quad \mathbf{T}_i = \begin{bmatrix} T_{i,11} & T_{i,12} \\ T_{i,21} & T_{i,22} \end{bmatrix}, \quad \mathbf{T}_d = \begin{bmatrix} T_{d,11} & T_{d,12} \\ T_{d,21} & T_{d,22} \end{bmatrix}, \quad \mathbf{N}_d = \begin{bmatrix} N_{d,11} & N_{d,12} \\ N_{d,21} & N_{d,22} \end{bmatrix}. \quad (3.1)$$

Este important de menționat faptul că regulatorul PID trebuie să fie implementabil din punct de vedere fizic. În acest scop, a fost introdusă matricea  $\mathbf{N}_d$  în partea de numitor a componentei derivate, ale cărei elemente sunt, în mod obișnuit, supraunitare și au valori relativ mari (adesea, cuprinse între 10 și 150, conform literaturii de specialitate). Acest artificiu filtrează componenta derivativă cu un filtru de ordin I, având bandă largă (sau foarte largă), ceea ce permite realizabilitatea fizică a întregului regulator.

Regulatorul PID multi-variabil trebuie proiectat potrivit unor performanțe dorite, care se referă, în principal, la buna urmărire a referințelor  $y_{r\{1,2\}}$  și robustețea în fața perturbațiilor până la o anumită intensitate.

## 3.2 Discretizarea regulatorul PID prin Metoda Biliniară (Tustin)

În cadrul proiectării reguletoarelor digitale, trecerea de la modelul în timp continuu la unul discret reprezintă un pas esențial pentru implementarea practică în sisteme numerice. Printre metodele consacrate de discretizare, Transformarea Biliniară – cunoscută și sub denumirea de „Transformarea lui Tustin” (TT) – este frecvent utilizată, datorită capacității sale de a conserva stabilitatea sistemului continuu și de a aproxima corect comportamentul dinamic.

Această metodă constă în înlocuirea variabilei  $s$ , specifică domeniului complex al Transformatei Laplace (TL), cu o variabilă  $z$  în domeniul complex al Transformatei Z (TZ), folosind o aproximație rațională, bazată pe aproximări Taylor de ordin I a exponenialei. Substituția utilizată de către TT are proprietatea de a proiecta axa imaginară a domeniului complex TL pe cercul unitar din domeniul complex TZ. Mai mult, semiplanele având partea reală negativă din domeniul complex TL sunt asociate cu zone circulare sau eliptice din interiorul cercului unitar al domeniului complex TZ. În

acest mod, stabilitatea sistemului în timp continuu este conservată în domeniul discret, aspect esențial pentru implementarea reguletoarelor numerice.

Formularea matematică a acestei substituții este exprimată astfel:

$$z = e^{sT_s} = \frac{e^{\frac{sT_s}{2}}}{e^{-\frac{sT_s}{2}}} \cong \frac{1 + \frac{sT_s}{2}}{1 - \frac{sT_s}{2}} = \frac{2 + sT_s}{2 - sT_s}, \quad (3.2)$$

unde  $T_s$  reprezintă perioada de eșantionare considerată.

Din relația (3.2), se deduce expresia variabilei  $s$  în funcție de variabila  $z$ :

$$s \cong \frac{2}{T_s} \frac{z-1}{z+1} = \frac{2}{T_s} \frac{1-z^{-1}}{1+z^{-1}}. \quad (3.3)$$

Astfel, fiecare termen al regulatorului PID poate fi rescris într-o formă discretizată, utilizând TT. Această conversie permite obținerea unei expresii în funcție de  $z^{-1}$ , adecvată pentru implementarea numerică a regulatorului folosind filtre numerice.

În cele ce urmează, vor fi prezentate relațiile detaliate prin care se obțin coeficienții numerici ai regulatorului discret, exprimați în funcție de parametrii din matricile (3.1) ale regulatorului continuu și  $T_s$ .

Pentru a putea deduce relațiile discrete corespunzătoare, este indicat să se pornească de la forma generală a regulatorului PID exprimată în domeniul continuu. Pe baza acestei expresii, se aplică ulterior TT asupra fiecărui termen component, obținându-se, astfel, forma discretizată completă, adecvată implementării numerice.

Matricea de transfer a regulatorului PID în timp continuu este:

$$C(s) = K_p + \frac{\mathbb{U}}{\mathbb{T}_i s} + \frac{\mathbf{T}_d s}{\left( \mathbb{U} + \frac{\mathbf{T}_d}{\mathbf{N}_d} s \right)} = \frac{K_p \cdot \mathbf{T}_i \cdot (1 + \boldsymbol{\tau}_d s) s + \mathbb{U} + \boldsymbol{\tau}_d s + \mathbf{T}_i \cdot \mathbf{T}_d s^2}{\mathbf{T}_i \cdot (\mathbb{U} + \boldsymbol{\tau}_d s) s}, \quad (3.4)$$

unde notațiile  $\frac{\bullet}{\bullet}$  și  $\bullet \cdot \bullet$  reprezintă, prin convenție, operațiile de împărțire, respectiv

înmulțire de matrici la nivel de element,  $\mathbb{U} = \begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix}$ , iar  $\boldsymbol{\tau}_d = \frac{\mathbf{T}_d}{\mathbf{N}_d}$  este o notație

simplificatoare care se referă, de fapt, la constantele de timp ale filtrului de realizabilitate fizică.

Ecuția (3.4) se poate exprima, în mod echivalent prin:

$$C(s) = \frac{\mathbb{U} + (\mathbf{K}_p \cdot \mathbf{T}_i + \boldsymbol{\tau}_d) s + \mathbf{T}_i \cdot (\mathbf{K}_p \cdot \boldsymbol{\tau}_d + \mathbf{T}_d) s^2}{\mathbf{T}_i \cdot (\mathbb{U} + \boldsymbol{\tau}_d s) s}. \quad (3.5)$$

Facând substituția (3.3) în expresia (3.5), după câteva calcule algebrice, se obține:

$$C_d(z^{-1}) = \frac{\mathbf{R}(z^{-1})}{\mathbf{S}(z^{-1})} = \frac{\mathbf{R}_0 + \mathbf{R}_1 z^{-1} + \mathbf{R}_2 z^{-2}}{\mathbf{S}_0 + \mathbf{S}_1 z^{-1} + \mathbf{S}_2 z^{-2}}, \quad (3.6)$$

unde:

$$\begin{cases} \mathbf{R}_0 = \mathbb{U} + \frac{2}{T_s} (\mathbf{K}_p \cdot \mathbf{T}_i + \boldsymbol{\tau}_d) + \frac{4}{T_s^2} \mathbf{T}_i \cdot (\mathbf{K}_p \cdot \boldsymbol{\tau}_d + \mathbf{T}_d) \\ \mathbf{R}_1 = 2 \left[ \mathbb{U} - \frac{4}{T_s^2} \mathbf{T}_i \cdot (\mathbf{K}_p \cdot \boldsymbol{\tau}_d + \mathbf{T}_d) \right] \end{cases} ; \quad (3.7)$$

$$\begin{cases} \mathbf{R}_2 = \mathbb{U} - \frac{2}{T_s} (\mathbf{K}_p \cdot \mathbf{T}_i + \boldsymbol{\tau}_d) + \frac{4}{T_s^2} \mathbf{T}_i \cdot (\mathbf{K}_p \cdot \boldsymbol{\tau}_d + \mathbf{T}_d) \\ \mathbf{S}_0 = \frac{2}{T_s} \mathbf{T}_i \cdot \left( \mathbb{U} + \frac{2\boldsymbol{\tau}_d}{T_s} \right) \\ \mathbf{S}_1 = -\frac{8}{T_s^2} \mathbf{T}_i \cdot \boldsymbol{\tau}_d \\ \mathbf{S}_2 = \frac{2}{T_s} \mathbf{T}_i \cdot \left( \frac{2\boldsymbol{\tau}_d}{T_s} - \mathbb{U} \right) \end{cases} . \quad (3.8)$$

Este bine de menționat că anumite configurații ale regulatorului pot fi analizate separat, evidențiind următoarele cazuri particular:

- PI:  $\mathbf{T}_d = \mathbb{O}$ ,  $(\mathbf{N}_d = \infty * \mathbb{U}) \Rightarrow \boldsymbol{\tau}_d = \mathbb{O}$  (caz întâlnit frecvent în practică);
- PD:  $\mathbf{T}_i = \infty * \mathbb{U}$  (caz care nu garantează anularea erorii de urmărire);
- ID:  $\mathbf{K}_p = \mathbb{O}$  (caz de evitat, deoarece nu se mai garantează câștigul dorit);
- P:  $\mathbf{T}_i = \infty * \mathbb{U}$ ,  $\mathbf{T}_d = \boldsymbol{\tau}_d = \mathbb{O}$  (caz care nu permite anularea erorii de urmărire).

În expresiile de mai sus, a fost folosită notația naturală  $\mathbb{O} = \begin{bmatrix} 0 & 0 \\ 0 & 0 \end{bmatrix}$ .

Pornind de la expresiile (3.7) și (3.8), coeficienții regulatorului pot fi implementați direct în structura unui algoritm de control digital. Totuși, în cazul unor configurații particulare, precum lipsa componentei integrale ( $\mathbf{T}_i = \infty * \mathbb{U}$ ), pot apărea expresii de forma  $\infty/\infty$ , care trebuie evitate. În mediul de programare MATLAB™, astfel de expresii, ca și expresiile de forma  $0/0$ , primesc valoarea indecisă **NaN** (*Not-a-Number*).

Pentru a evita astfel de ambiguități și pentru a asigura o implementare robustă, se recomandă o normalizare prealabilă a matricilor (3.9) cu factorul  $\frac{2\mathbf{T}_i}{T_s}$ . Această

operație elimină incertitudinea numerică și permite exprimarea tuturor coeficienților într-o formă bine determinată, indiferent de valorile parametrilor regulatorului.

Astfel, expresiile pre-finale ale matricilor în curs de pregătire pentru implementare sunt:

$$\begin{cases} \mathbf{R}_0 = \frac{T_s}{2} \frac{\mathbb{U}}{\mathbf{T}_i} + \left( \mathbf{K}_p + \frac{\boldsymbol{\tau}_d}{\mathbf{T}_i} \right) + \frac{2}{T_s} (\mathbf{K}_p \cdot \boldsymbol{\tau}_d + \mathbf{T}_d) \\ \mathbf{R}_1 = T_s \frac{\mathbb{U}}{\mathbf{T}_i} - \frac{4}{T_s} (\mathbf{K}_p \cdot \boldsymbol{\tau}_d + \mathbf{T}_d) \\ \mathbf{R}_2 = \frac{T_s}{2} \frac{\mathbb{U}}{\mathbf{T}_i} - \left( \mathbf{K}_p + \frac{\boldsymbol{\tau}_d}{\mathbf{T}_i} \right) + \frac{2}{T_s} (\mathbf{K}_p \cdot \boldsymbol{\tau}_d + \mathbf{T}_d) \end{cases} ; \quad (3.9)$$

$$\begin{cases} \mathbf{S}_0 = \mathbb{U} + \frac{2\boldsymbol{\tau}_d}{T_s} \\ \mathbf{S}_1 = -\frac{4}{T_s}\boldsymbol{\tau}_d \\ \mathbf{S}_2 = \frac{2\boldsymbol{\tau}_d}{T_s} - \mathbb{U} \end{cases} \quad (3.10)$$

Pentru a facilita implementarea numerică și analiza comparativă a comportamentului regulatorului, se va recurge la o a doua normalizare a matricilor (3.9) și (3.10) cu matricea  $\mathbf{S}_0$ . Acest demers are ca scop simplificarea relațiilor matematice și aducerea numitorului fracției (3.6) la forma canonică (unde termenul liber este unitar). Prin urmare, matricile (3.9) și (3.10) devin:

$$\begin{cases} \mathbf{R}_i \leftarrow \frac{\mathbf{R}_i}{\mathbf{S}_0}, \quad \forall i \in \overline{0,2} \\ \mathbf{S}_0 \leftarrow \mathbb{U} \\ \mathbf{S}_j \leftarrow \frac{\mathbf{S}_j}{\mathbf{S}_0}, \quad \forall j \in \overline{1,2} \end{cases} \quad (3.11)$$

Astfel, numărul matricilor de coeficienți pentru PID discret a scăzut de la 6 la 5, ceea ce permite simularea numerică cu o viteză de calcul mai mare.

### 3.3 Determinarea regulatorului PID optimal cu ajutorul GWO

În etapa de analiză a răspunsului în timp al sistemului, este esențial să se facă o distincție clară între regimurile tranzitoriu și staționar ale fiecărui semnal. În practică, această separare poate deveni dificilă în prezența perturbațiilor stocastice, care afectează comportamentul semnalului și pot masca tranziția dintre cele două regimuri. Metodologia de identificare a acestor regiuni este descrisă în lucrarea [StCu-2021], și se bazează pe calculul deviației standard a semnalului, începând de la sfârșitul acestuia către început, pentru a detecta pragul de stabilizare.

În urma stabilirii unei perechi de referințe discrete pentru ieșirile sistemului ( $y_1^{\text{ref}}$  și  $y_2^{\text{ref}}$ ), acestea prezintă o durată specificată  $N$ , care nu este neapărat aceeași cu lungimea semnalelor utilizate în fazele de identificare sau validare. În general, referințele sunt alese astfel încât să corespundă unor trepte constante pe fiecare ieșire în parte (treptele nefiind neapărat egale). În consecință, sistemului i se asociază o pereche de comenzi statice provenite dintr-o hartă statică prestabilită a sistemului ce trebuie controlat:  $u_1^{\text{sta}}$  și  $u_2^{\text{sta}}$ .

Dacă regulatorul MIMO-PID este suficient de bine acordat și oferă performanțe satisfăcătoare, se observă că răspunsurile sistemului tind să urmeze aceste referințe începând cu anumite momente de timp, notate  $n_1^{\text{tr}} + 1$  și  $n_2^{\text{tr}} + 1$ , pentru fiecare ieșire în parte. Valorile  $n_1^{\text{tr}}$  și  $n_2^{\text{tr}}$  indică sfârșitul regimului tranzitoriu pentru ieșirile simulate  $y_1^{\text{sim}}$ , respectiv  $y_2^{\text{sim}}$ . Aceste momente pot fi identificate și în variația comenzilor generate de regulator, corespunzătoare semnalelor de control  $u_1$  și  $u_2$ . Totuși, în situațiile în care regulatorul nu oferă performanțe mulțumitoare, comenzile rezultate pot prezenta variații semnificative chiar și în regim staționar, ceea ce conduce la o identificare dificilă, chiar imposibilă, a regimurilor staționare.

Pentru a depăși această dificultate, se propune impunerea unei separări comune a celor două regimuri – tranzitoriu și staționar – prin utilizarea unei valori medii între momentele  $n_1^{\text{tr}}$  și  $n_2^{\text{tr}}$ . Această medie reprezintă o alegere naturală atunci când se dorește sincronizarea deciziilor asupra celor două ieșiri, iar rotunjirea la cel mai apropiat întreg asigură compatibilitatea cu implementările numerice discrete. Formula adoptată este redată mai jos, oferind astfel un reper clar și unitar pentru analiza ulterioară a performanței regulatorului:

$$m^{\text{tr}} = \left\lfloor \frac{n_1^{\text{tr}} + n_2^{\text{tr}} + 1}{2} \right\rfloor. \quad (3.12)$$

Pentru a evalua performanța globală a regulatorului, se definește un criteriu de optimizare compus, care să ia în considerare atât comportamentul comenzilor, cât și cel al ieșirilor. Fiecare dintre aceste două componente contribuie în mod egal la valoarea finală a funcției de performanță, exprimată procentual. Mai precis, acest criteriu este formulat ca:

$$V = 50(V_y + V_u) [\%], \quad (3.13)$$

unde  $V_y$  reflectă calitatea urmăririi referinței de către ieșiri, iar  $V_u$  cuantifică performanța comenzii. Fiecare dintre aceste valori este, la rândul ei, împărțită în două contribuții: una asociată regimului tranzitoriu și alta regimului staționar.

În cazul ieșirilor, expresia utilizată pentru calculul performanței este:

$$V_y = \frac{1}{2N} \left( \frac{n_1^{\text{tr}} + n_2^{\text{tr}}}{1 + \mu_y^{\text{tr}} f_y^{\text{tr}}} + \frac{2N - n_1^{\text{tr}} - n_2^{\text{tr}}}{1 + \mu_y^{\text{sta}} f_y^{\text{sta}}} \right) \in (0, 1], \quad (3.14)$$

unde factorii  $f_y^{\text{tr}}$  și  $f_y^{\text{sta}}$  indică erorile maxime în regimul tranzitoriu, respectiv staționar, definite astfel:

$$f_y^{\text{tr}} = \left\| \begin{bmatrix} \varepsilon_{y,1}^{\text{tr}} \\ \varepsilon_{y,2}^{\text{tr}} \end{bmatrix} \right\|, \quad f_y^{\text{sta}} = \max \left\{ \max \left\{ \left| \varepsilon_{y,1}^{\text{sta}} \right| \right\}, \max \left\{ \left| \varepsilon_{y,2}^{\text{sta}} \right| \right\} \right\}, \quad (3.15)$$

iar vectorii de eroare pentru fiecare regim sunt construiți ca mai jos:

$$\begin{cases} \varepsilon_{y,j}^{\text{tr}} = \left[ y_j^{\text{sim}}[1] - y_j^{\text{ref}}[1] \quad \cdots \quad y_j^{\text{sim}}[n_j^{\text{tr}}] - y_j^{\text{ref}}[n_j^{\text{tr}}] \right]^T \\ \varepsilon_{y,j}^{\text{sta}} = \left[ y_j^{\text{sim}}[n_j^{\text{tr}} + 1] - y_j^{\text{ref}}[n_j^{\text{tr}} + 1] \quad \cdots \quad y_j^{\text{sim}}[N] - y_j^{\text{ref}}[N] \right]^T \end{cases}, \quad \forall j \in \{1, 2\}. \quad (3.16)$$

Pentru a asigura o influență echilibrată a fiecărei secțiuni temporale, sunt introduse și senzitivități invers proporționale cu durata fiecărui regim tranzitoriu, date de:

$$\mu_y^{\text{tr}} = \frac{1}{n_1^{\text{tr}} + n_2^{\text{tr}}}, \quad \mu_y^{\text{sta}} = \frac{1}{2N - n_1^{\text{tr}} - n_2^{\text{tr}}}. \quad (3.17)$$

În definițiile prezentate anterior, vectorii  $\varepsilon_{y,j}^{\text{tr}}$  și  $\varepsilon_{y,j}^{\text{sta}}$  (pentru  $\forall j \in \{1, 2\}$ ), reprezintă erorile de urmărire ale semnalelor de ieșire în regimul tranzitoriu, respectiv staționar. Scopul optimizării este minimizarea acestor erori, utilizând două norme distincte: norma Euclidiană (L2) pentru zona tranzitorie, respectiv norma infinit (L $\infty$ ) pentru zona staționară.

Alegerea acestor norme reflectă caracterul specific al celor două regimuri: în faza tranzitorie, contează distribuția globală a abaterilor (care trebuie să fie cât mai reduse în norma L2), în timp ce, în regimul staționar, accentul cade pe eroarea maximă

globală (care trebuie să fie minimă, conform normei  $L_\infty$ ). Pentru asigurarea unei echilibrări între contribuțiile fiecărui regim la valoarea finală a criteriului, se utilizează ponderile inverse, astfel încât o durată mai scurtă să aibă o influență mai mare asupra rezultatului final și reciproc.

De asemenea, ponderile definite în relația (3.17) au fost alese în așa fel încât valoarea criteriului  $V_y$  să fie superioară pragului de  $1/2$ , în cazul unui regulator performant. În plus, utilizarea unei forme hiperbolice de normalizare, inspirată din relația (2.26), asigură că valorile criteriului rămân în intervalul  $(0,1]$ , evitând, astfel, apariția unor punctaje artificial de mari, generate de o performanță excelentă pe un singur canal de ieșire, dar deficitară pe celălalt.

Prin analogie cu ieșirile, în cazul comenzilor, se definește o expresie de evaluare a performanței, notată  $V_u$ , care reflectă stabilitatea și efortul de control necesar atingerii regimului staționar. Deși structura generală este similară, formularea matematică a lui  $V_u$  diferă ușor, luând în calcul particularitățile comenzilor:

$$V_u = \frac{1}{N} \left( \frac{m^{\text{tr}}}{1 + \mu_u^{\text{tr}} f_u^{\text{tr}}} + \frac{N - m^{\text{tr}}}{1 + \mu_u^{\text{sta}} f_u^{\text{sta}}} \right) \in (0,1]. \quad (3.18)$$

Factorii  $f_u^{\text{tr}}$  și  $f_u^{\text{sta}}$  din definiția (3.18) sunt norme asociate comenzii din regimul tranzitoriu, respectiv, erorii față de comenzile de referință din regimul staționar, definite prin relațiile:

$$f_u^{\text{tr}} = \left\| \begin{bmatrix} u_1^{\text{tr}} \\ u_2^{\text{tr}} \end{bmatrix} \right\|, \quad f_u^{\text{sta}} = \left\| \begin{bmatrix} \varepsilon_{u,1}^{\text{sta}} \\ \varepsilon_{u,2}^{\text{sta}} \end{bmatrix} \right\|, \quad (3.19)$$

unde:

$$\begin{cases} u_i^{\text{tr}} = [u_i[1] \quad \dots \quad u_i[m^{\text{tr}}]]^T \\ \varepsilon_{u,j}^{\text{sta}} = [u_i[m^{\text{tr}} + 1] - u_i^{\text{sta}} \quad \dots \quad u_i[N] - u_i^{\text{sta}}]^T, \quad \forall i \in \{1,2\}. \end{cases} \quad (3.20)$$

Senzitivitățile asociate fiecărui regim sunt, similar cu situația semnalelor de ieșire, invers proporționale cu duratele timpilor tranzitorii respectivi:

$$\mu_u^{\text{tr}} = \frac{1}{2m^{\text{tr}}}, \quad \mu_u^{\text{sta}} = \frac{1}{2(N - m^{\text{tr}})}. \quad (3.21)$$

În plus, în situațiile în care sistemul nu dispune de o hartă statică de referință pentru comenzile staționare, valorile  $u_i^{\text{sta}}$  pot fi înlocuite cu media comenzilor în regim staționar:

$$u_i^{\text{sta}} = \frac{1}{N - m^{\text{tr}}} \sum_{n=m^{\text{tr}}+1}^N u_i[n], \quad \forall i \in \{1,2\}. \quad (3.22)$$

Totuși, este important de menționat că, în absența unei hărți statice și în condițiile în care comenzile ating rapid valorile de saturație (fenomen care este de evitat, deoarece suprasolicită elementele de execuție), valoarea criteriului optimal crește în mod artificial, fapt care potențează riscul ca  $f_u^{\text{sta}}$  să devină zero sau foarte mic, conducând la o supraestimare a performanței, prin maximizarea nejustificată a valorii  $V_u$ . Astfel, chiar dacă sistemul pare stabilizat, lipsa unei referințe clare sau a

unei dinamici reale poate compromite validitatea interpretării indicatorului. În asemenea cazuri, evaluarea obiectivă a regulatorului devine considerabil mai dificilă.

Pe baza formulării criteriului compus de optimizare (ecuația (3.13)), se pot determina valorile optime ale parametrilor regulatorului PID în timp continuu. Aceștia urmează a fi ulterior discretizați pentru implementarea numerică. Procesul de optimizare presupune maximizarea valorii funcției obiectiv și poate fi realizat eficient prin utilizarea metaheuristicii GWO, care a demonstrat o bună capacitate de explorare și convergență în contextul sistemelor neliniare cu mai multe intrări și ieșiri.

### 3.4 Schema de control multi-variabil cu regulatorul PID discret

Pentru a evidenția modul de funcționare al regulatorului PID discret integrat într-un sistem multi-variabil, se poate utiliza reprezentarea schematică a buclei de reglare ca în Figura 3.2.




Figura 3.2 Schema control automat folosind regulatorul PID multi-dimensional

Această diagramă oferă o perspectivă clară asupra interacțiunilor dintre variabilele de intrare și cele de ieșire, precum și asupra modului în care matricile globale de reglare  $\mathbf{R}$  și  $\mathbf{S}$  (din ecuația (3.6)) contribuie la generarea semnalelor de control. Figura 3.2 ilustrează arhitectura generală a sistemului de reglare, punând accent pe structura blocurilor funcționale și pe traiectoria semnalelor într-o configurație 2-MISO.

Blocurile de reglare sunt reprezentate sub forma unor filtre raționale, ale căror polinoame sunt extrase din matricile  $\mathbf{R}$  și  $\mathbf{S}$ :

$$\begin{cases} R_{ij}(z^{-1}) = r_{ij}^0 + r_{ij}^1 z^{-1} + r_{ij}^2 z^{-2} \\ S_{ij}(z^{-1}) = 1 + s_{ij}^1 z^{-1} + s_{ij}^2 z^{-2} \end{cases}, \quad \forall i, j \in \{1, 2\}. \quad (3.23)$$

Așa cum arată ecuația (3.23), toate polinoamele sunt de gradul 2, fapt deloc surprinzător, având în vedere că matricea de transfer a regulatorului PID în timp continuu conține tot rapoarte de polinoame cu gradul 2.



## 4 Studiu de caz: instalația didactică ASTANK2

### 4.1 Scurtă descriere a instalației ASTANK2

#### 4.1.1 Prezentare generală

Instalația ASTANK2 este un echipament didactic și de cercetare utilizat pentru investigarea comportamentului sistemelor hidraulice cu mai multe variabile. Aceasta permite testarea și compararea strategiilor de reglare într-un cadru controlabil, reproducând în mod fidel procese cu dinamică reală. Structura instalației este concepută pentru a reflecta un sistem de distribuție a apei în regim industrial, incluzând două rezervoare de lucru cu geometrie distinctă și un rezervor de acumulare, toate interconectate printr-o rețea de elemente active și pasive: pompe, electrovalve, senzori și robinete. Conform [CuStDu-2015], arhitectura flexibilă permite configurarea cu ușurință a experimentelor, fie în mod decuplat, fie în regim de cuplare hidraulică, oferind suportul necesar, atât pentru analiza staționară, cât și pentru studiul tranzitoriu al procesului. Schema de principiu a instalației ASTANK 2 este ilustrată în Figura 4.1.




Figura 4.1 Schema structurală a instalației didactice ASTANK2.

(Imagine preluată din publicația [CuStDu-2015], cu acordul autorilor.)

Se observă geometria variabilă a rezervorului 1, din stânga, fapt care accentuează comportamentul neliniar pe primul canal de ieșire, constituit de nivelul lichidului în acest rezervor. Al doilea canal de ieșire este reprezentat de nivelul de lichid din rezervorul 2 (cel din dreapta), cu geometrie paralelipipedică, dar comportament tot neliniar (conform legilor de Fizică Hidraulică). Fiecare rezervor are o scurgere în partea inferioară, al cărei debit se poate regla manual printr-un robinet (R11, respectiv R21,

în schemă). Închidere completă a robinetului de scurgere permite doar umplerea rezervoarelor, fenomen care nu prezintă un interes major pentru controlul automat. De aceea, cele două robinete sunt lăsate pe poziția (parțial) deschis, pentru a permite recircularea lichidului prin cuva inferioară. Alimentarea rezervoarelor este asigurată de pompa principală P care urcă lichidul din cuva inferioară până la conductele superioare, ale căror debite sunt reglate fie manual (prin intermediul robinetelor R12 și R22), fie automat, prin intermediul electrovalvelor controlate FC1 și FC2. Pentru funcționarea instalației în vederea identificării și controlului automat, robinetele R12 și R22 sunt fixate în poziția „complet deschis”, urmând ca electrovalvele să fie responsabile integral de debitul de umplere a rezervoarelor.

Rezervoarele pot comunica sau nu între ele printr-o conductă aflată la baza acestora. Reglarea debitului de comunicație se efectuează prin robinetul R montat pe conductă. Dacă robinetul este închis, instalația lucrează complet decuplat, ca un ansamblu de două sub-sisteme SISO independente. Pentru a obține un comportament de sistem MIMO, robinetul de comunicație trebuie deschis (nu neapărat la maxim). Practic, acesta controlează gradul de cuplare/decuplare al celor două subsisteme. În mod normal, ieșirile (cele două niveluri de lichid) se influențează reciproc, după principiul vaselor comunicante. Totuși, o serie de experimente au arătat că dinamica de echilibrare a nivelurilor de lichid este mult mai lentă decât cea de umplere sau golire a rezervoarelor, mai ales dacă diferența dintre nivelurile inițiale din rezervoare și cele cerute ca referințe este mare. În plus, dacă robinetul R este fixat pe o poziție parțial închisă/deschisă, se poate stabili un anumit grad de decuplare/cuplare între cele două ieșiri. Din acest motiv, sistemul de tip MIMO al instalației poate fi aproximat cu destulă precizie printr-un ansamblu de două sub-sisteme de tip MISO, dacă, de exemplu, robinetul R este închis pe jumătate.

Intrările de comandă se aplică electrovalvelor FC1 și FC2 aflate deasupra rezervoarelor. Ele sunt semnale electrice a căror tensiune variază în plaja 2–10 V.

Din punct de vedere al configurației fizico-funcționale, instalația ASTANK2 oferă un suport experimental valoros pentru testarea controlului multivariabil, datorită distribuției sale modulare și capacității de a introduce neliniarități controlate în comportamentul sistemului. Particularitățile geometrice ale rezervoarelor generează comportamente dinamice distincte, relevante pentru studiul modelelor din clasa NARMAX.

#### 4.1.2 Caracteristici funcționale și constrângeri

O atenție specială trebuie acordată **limitărilor constructive** impuse de echipamentele utilizate. După cum se menționează în [CuSt-2017], comenzile aplicate electrovalvelor prezintă câteva particularități în plus față de limitele de saturație la 2 V și 10 V. În primul rând, tensiunile de la care electrovalvele încep efectiv să reacționeze sunt superioare valorii de 3 V. În al doilea rând, variațiile admise de către electrovalve între două valori succesive de tensiune sunt limitate la un salt maxim de 3 V. Aceste constrângeri influențează atât faza de identificare statică a sistemului, cât și performanța regulatorului, chiar optimal fiind.

Pentru a dimensiona corect comenzile, se pot utiliza caracteristicile statice ale instalației, ce formează două hărți statice. Fiecare hartă reflectă relația funcțională dintre comenzile aplicate și valorile staționare ale unei ieșiri. Aceste hărți sunt obținute în urma unui proces de identificare experimentală statică, realizat prin aplicarea unor combinații de comenzi constante ( $u_1$ ,  $u_2$ ) și înregistrarea răspunsurilor sistemului în regim staționar ( $y_1$ , respectiv  $y_2$ ). În urma experimentelor, s-a constatat că fiecare

hartă statică arată ca un plan în spațiul tridimensional determinate de cele două comenzi (ca plan orizontal) și ieșirea măsurată (ca axă verticală). Prin urmare, o astfel de hartă statică poate fi modelată cu ajutorul unui plan înclinat, descris de ecuația:

$$y = a_1 u_1 + a_2 u_2 + y_0, \quad (4.1)$$

unde coeficienții  $a_1$ ,  $a_2$  și termenul liber  $y_0$  sunt estimați prin MCMMP. Acest demers permite construirea a două plane statice – câte unul pentru fiecare ieșire – care descriu suprafețele de răspuns ale instalației în regim staționar. Ulterior, aceste suprafețe sunt utilizate pentru a determina punctele nominale admisibile de lucru ale instalației și pentru a extrage comenzile statice corespunzătoare unor ieșiri dorite.

Astfel, pentru fiecare ieșire, se folosește o relație precum (4.1), care permite calculul invers al comenzilor corespunzătoare acestei. Fiind disponibile două ecuații statice – câte una pentru fiecare canal de ieșire – se poate aborda problema inversă: determinarea comenzilor statice corespunzătoare unor perechi de referințe. În acest scop, se construiesc doi vectori de referințe posibile, pentru  $Y_{r1}$  și  $Y_{r2}$ , generați uniform în intervalele valorilor minime și maxime măsurate, cu o rezoluție maximă de 0.01 cm. Pentru fiecare combinație  $(Y_{r1}, Y_{r2})$ , se încearcă rezolvarea sistemului de ecuații liniare:

$$\begin{cases} Y_{r1} = a_{1,1}U_1 + a_{1,2}U_2 + y_{0,1} \\ Y_{r2} = a_{2,1}U_1 + a_{2,2}U_2 + y_{0,2} \end{cases}. \quad (4.2)$$

Dacă există o soluție,  $(U_1, U_2)$ , atunci referințele sunt bine alese. Dacă nu (sistemul poate fi incompatibil), atunci cel puțin una dintre referințe este inadecvată. De exemplu, este imposibil ca instalația să opereze cu 3 cm de lichid în primul rezervor și 10 cm de lichid în al doilea rezervor, deoarece nu există comenzi admisibile pe electrovalve pentru această combinație de ieșiri.

Pentru a verifica dacă o combinație de referințe  $(Y_{r1}, Y_{r2})$  este admisibilă, se evaluează dacă acesta corespunde simultan unei valori valide pe ambele plane statice identificate – adică dacă punctele din spațiu  $U_1(Y_{r1}, Y_{r2})$  și  $U_2(Y_{r1}, Y_{r2})$  se află pe aceeași verticală. Această restricție este mai ușor de vizualizat cu ajutorul Figurii 4.2.




Figura 4.2 Zona de referințe și comenzi statice admisibile ale instalației ASTANK2.

Astfel, pornind de la sistemul (4.2), se construiesc două plane inverse,  $u_1(y_1, y_2)$  și  $u_2(y_1, y_2)$ , care sunt intersectate. Valorile de comandă care ies din domeniul admisibil (cel în care sistemul (4.2) are soluții) sunt înlăturate (sau, opțional, marcate cu valoarea 0). Rezultatul este reprezentat de două plane de comenzi admisibile,  $U_{a1}$  și  $U_{a2}$ , exprimate în funcție de referințele admisibile  $Y_{a1}$  și  $Y_{a2}$ , care definesc comenzile statice efectiv utilizabile în procesul de control. De exemplu, privind Figura 4.2, se poate observa că, deși nivelul de 10 cm din al doilea rezervor ar putea fi atins, pentru că nivelul de 3 cm din primul rezervor este nerealist de mic, nu există comenzi statice admisibile. O referință admisibilă apropiată este cea din jurul lui 6 cm, deoarece verticala dusă prin punctul (6,10) străpunge ambele plane din figură. Cele două puncte de străpungere oferă cele două comenzi statice. În cazul combinației de referințe (6,10) cm, comenzile statice aferente sunt (2.44,9) V. Desigur, având în vedere limitările constructive ale electrovalvelor, chiar dacă aceste referințe și comenzi statice fac parte din domeniul admisibil, este posibil ca instalația ASTANK2 să nu reacționeze corect la o comandă sub 3 V.

Prin urmare, chiar dacă utilizatorul nu știe cu precizie ce combinație de referințe este admisibilă, în cazul în care propunerea lui eșuează, i se poate propune o combinație admisibilă de referințe, păstrând una dintre ele așa cum a fost aleasă la început.

Pentru exemplificare, în tabelul de mai jos sunt prezentate valorile de referință selectate pentru cele două ieșiri ale sistemului,  $\{y_{r1}, y_{r2}\}$ , împreună cu comenzile statice corespunzătoare acestora,  $\{u_{s1}, u_{s2}\}$ , determinate pe baza intersecției suprafețelor identificate din harta statică.

Tabelul 4.1 *Un punct nominal de funcționare al instalației ASTANK2.*

| $y_{r1}$ [cm] | $y_{r2}$ [cm] | $u_{s1}$ [V] | $u_{s2}$ [V] |
|---------------|---------------|--------------|--------------|
| 8             | 9             | 5.39         | 7.07         |

## 4.2 Organizarea simulărilor

Simulările au fost realizate utilizând două abordări distincte pentru modelarea procesului: una bazată pe structura 2-MISO-ARX și cealaltă utilizând un model 2-MISO-NARX, fiecare cu propriile particularități în implementare și reglare.

Programul de simulare are trei etape majore:

1. Identificarea modelelor optimale de tip ARX și NARX, cu ajutorul MMEP, MCMMP și GWO, folosind date intrare-ieșire reale, achiziționate de la instalația ASTANK2.
2. Determinarea reguletoarelor PID optimale pentru modelele identificate, folosind GWO.
3. Demonstrarea performanțelor reguletoarelor PID optimale determinate.

Pentru implementarea modelului MIMO-ARX, s-a utilizat o schemă dedicată în SIMULINK™, în care modelul multivariabil MIMO a fost divizat în două sub-sisteme MISO cu ieșiri independente, conform abordării descrise în Capitolul 2. Figurile 4.3 și 4.4 evidențiază clar cele două componente structurale corespunzătoare fiecărei ieșiri, ambele fiind comandate de cele două semnale de intrare.

În cadrul ambelor scheme, sunt incluse blocuri de saturație aplicate comenzilor, menite să limiteze valorile acestora în conformitate cu constrângerile constructive impuse, și anume intervalul [2,10] V. De asemenea, pentru a reda comportamentul stocastic al sistemului real, au fost adăugate două surse independente de zgomot alb, câte una pentru fiecare sub-sistem, astfel încât să se poată evalua robustețea

strategiilor de reglare în prezența perturbațiilor stocastice. Dispersiile zgomotelor albe de generat au fost estimate odată cu identificarea parametrilor optimali ai modelului 2-MISO-ARX.




Figura 4.3 Schema SIMULINK a sub-sistemului MISO asociat canalului 1 de ieșire.




Figura 4.4 Schema SIMULINK a sub-sistemului MISO asociat canalului 2 de ieșire.

Regulatele PID responsabile de sinteza comenzilor sunt prezentate în Figurile 4.5 (ca blocuri SIMULINK™) și 4.6 (elementele componente ale blocurilor SIMULINK™). Ele sunt adaptate individual pentru controlul precis al fiecărei ieșiri, în funcție de specificul dinamic al fiecărui canal.




Figura 4.5 Blocurile regulate discrete responsabile de sinteza comenzilor.




Figura 4.6 Componentele interne ale blocurilor reglatoare discrete.

Astfel, modelul 2-MISO-ARX implementat este utilizat pentru a genera valorile simulate ale ieșirilor și comenzilor, necesare evaluării performanței regulatorului prin intermediul funcției de performanță definite în capitolul precedent.

În paralel cu această abordare liniară, în continuare, se vor analiza și modele de tip 2-MISO-NARX, care permit surprinderea comportamentului neliniar al sistemului. Pentru acest caz, simularea în mediul SIMULINK™ s-a dovedit a fi extrem de sensibilă la instabilitate numerică, din cauza complexității introduse de structura modelului NARX multi-dimensional și, mai ales, a produselor dintre semnale. În acest context, sub îndrumarea profesorului coordonator, a fost concepută o funcție MATLAB™ care să reproducă comportamentul sistemului în mod echivalent, numită **NARX\_iter\_sim**. Ea permite obținerea semnalelor de ieșire necesare evaluării prin intermediul funcției de performanță, cu un mai bun control al stabilității numerice.

Funcția **NARX\_iter\_sim** utilizează discretizarea regulatorului PID prin TT, detaliată în capitolul precedent și aplicată aici în formă matricială, având în vedere că obiectivul lucrării este proiectarea unui regulator multi-dimensional capabil să controleze simultan cele două canale de ieșire. Odată obținuți, coeficienții discreți ai regulatorului sunt utilizați în implementarea numerică a legii de reglare, care se face prin intermediul unui set de ecuații cu diferențe.

Având în vedere că regulatorul PID discretizat conține termeni de tip  $z^{-2}$ , simularea în care participă toți coeficienții regulatorului PID începe abia de la a treia iterație a buclei principale, fiind necesară inițializarea sistemului cu cel puțin o pereche de date corespunzătoare celor două ieșiri. Această inițializare trebuie să țină cont că, în rezervoarele instalației se află deja o anumită cantitate de lichid, de regulă, la un nivel inferior referinței stabilite a fi urmărită. Demararea instalației cu rezervoarele goale ar trece printr-o serie de puncte nominale de funcționare, pentru care nu au fost identificate modele adecvate. Modelele identificate acoperă o plajă de puncte nominale de funcționare din jurul nivelurilor de lichid de 10 cm în primul rezervor și 9 cm în al doilea rezervor. Față de acestea, ele sunt capabile să funcționeze corect în plaja de 7–13 cm la primul rezervor și 6–12 cm la al doilea rezervor. De aceea, inițializarea procesului de umplere și, apoi, de menținere a nivelurilor dorite, se realizează plecând de la niveluri inițiale aflate în cele două plaje menționate. În cadrul buclei iterative principale, la fiecare pas temporal, se calculează comanda curentă, utilizând filtrele specifice ale regulatorului, care interacționează direct cu modelul NARX, pentru a genera dinamica completă a procesului.

Pentru estimarea ieșirilor sistemului, au fost utilizate două structuri **theta\_NARX**, câte una pentru fiecare canal. Acestea sunt utilizate în cadrul funcției **NARX\_iter\_sim**, care, pe baza celor două intrări de la momentul  $n$ , calculează ieșirea simulată a sistemului la același moment de timp, la care se adaugă valoarea curentă a unui zgomot Gaussian generat artificial. Acest mecanism este repetat iterativ în cadrul unei bucle **for**, până la finalul orizontului de simulare, generând, în final, evoluția completă a răspunsului sistemului în timp.

Pentru ca simulările să ofere un cadru comparabil între modelele ARX și NARX, a fost necesară configurarea riguroasă a algoritmului metaeuristic utilizat, GWO,



aplicat atât în etapa de identificare, cât și în etapa de optimizare a parametrilor regulatorului PID. Configurația acestuia a fost concepută astfel încât să asigure un echilibru între precizia soluției și eficiența computațională. Pentru etapa de identificare, numărul de lupi informatici a fost setat la 50, iar numărul maxim de iterații – la 1000. În ceea ce privește etapa de optimizare a regulatoarelor PID, numărul de lupi informatici a fost setat la 30, iar numărul maxim de iterații – la 500.

Un element esențial al acestei configurări îl constituie delimitarea spațiului de căutare, stabilită în concordanță cu specificul fiecărei probleme de optimizare. Intervalele de variație au fost alese astfel:

- în etapa de identificare, indicii structurali maximi ai modelelor au fost stabiliți la 30 pentru polinoamele aferente polilor și la 150 pentru polinoamele aferente zerourilor;
- pentru coeficienții matricilor  $K_p$  și  $T_d$ , domeniul de căutare a fost fixat în intervalul  $[0,50]$ ;
- pentru coeficienții matriciilor  $T_i$  și  $N_d$ , domeniul a fost extins la intervalul  $[0,150]$ , iar coeficienții  $N_d$  nu pot fi inferiori valorii 5.

Această selecție asigură un cadru realist și stabil de reglaj, reflectând limitele fizice ale sistemului, precum și nevoia de convergență eficientă în cadrul procesului de optimizare. Totodată, limitele de căutare astfel stabilite diminuează riscul de a exclude din spațiul de căutare soluții optimale cu bune performanțe.

### 4.3 Rezultate de identificare

Pentru a evalua eficiența metodei de identificare și a algoritmului de optimizare aplicat asupra sistemului ASTANK2, această secțiune prezintă rezultatele obținute atât grafic, cât și tabelar. Se începe cu reprezentarea semnalelor de stimul și de ieșire utilizate în procesul de identificare, ilustrate în Figura 4.7, urmate de cele aferente fazei de validare, din Figura 4.8.

În ambele figuri, semnalele de stimul, ilustrate în partea superioară, fac parte din categoria SPA, dar cu trepte. La generarea lor, s-a ținut cont de limitările constructive ale instalației ASTANK2. Treptele sunt prevăzute pentru a permite instalației să stabilizeze, măcar parțial, semnalele de ieșire, având în vedere că ea funcționează ca un sistem cu dinamică destul de lentă. Din acest motiv și perioada de eșantionare a semnalelor de intrare și ieșire a fost stabilită la o valoare adecvată:  $T_s = 1$  s. Durata de achiziție a datelor este de aproximativ 800 s. De menționat că datele de ieșire achiziționate, ilustrate în partea inferioară a figurilor, au fost netezite cu ajutorul filtrelor spline stocastice adaptive descrise în [StCu-2020].

Pe baza acestor date de intrare-ieșire, au fost identificate cele două modele aferente. Pentru modelul 2-MISO-ARX, s-au obținut indicii structurali optimali din Tabelul 4.2. Modelul 2-MISO-NARX este caracterizat de indicii structurali optimali din Tabelele 4.3 (cei majori) și 4.4 (cei minori). Au fost înlăturați din al doilea tabel indicii structurali minori inexistenți (cei care corespund indicilor structurali majori nuli).

Tabelul 4.2 *Indicii structurali optimali ai modelului 2-MISO-ARX.*

| $na_1$ | $nb_{11}$ | $nb_{12}$ | $na_2$ | $nb_{21}$ | $nb_{22}$ |
|--------|-----------|-----------|--------|-----------|-----------|
| 31     | 2         | 5         | 30     | 3         | 3         |

Tabelul 4.3 *Indicii structurali majori optimali ai modelului 2-MISO-NARX.*



| $P_1$ | $M_{11}$ | $M_{12}$ | $K_{11}$ | $K_{12}$ | $P_2$ | $M_{21}$ | $M_{22}$ | $K_{21}$ | $K_{22}$ |
|-------|----------|----------|----------|----------|-------|----------|----------|----------|----------|
| 1     | 0        | 1        | 2        | 1        | 3     | 1        | 2        | 0        | 0        |

Tabelul 4.4 *Indicii structurali minori optimali ai modelului 2-MISO-NARX.*

| $na_1$ | $nb_{11}$ | $nb_{12}$ | $na_2$ | $nb_{21}$ | $nb_{22}$ |
|--------|-----------|-----------|--------|-----------|-----------|
| 5      | 23        | 25        | 6      | 27        | 20        |


  

| $na_{11}$ | $nb_{121}$ | $nd_{111}$ | $nd_{112}$ | $nd_{121}$ | $na_{21}$ | $na_{22}$ | $na_{23}$ | $nb_{211}$ | $nb_{221}$ | $nb_{222}$ |
|-----------|------------|------------|------------|------------|-----------|-----------|-----------|------------|------------|------------|
| 20        | 23         | 21         | 22         | 24         | 1         | 14        | 30        | 6          | 27         | 22         |

Figura 4.7 *Semnale de stimulație generate și de ieșire achiziționate din instalația ASTANK2, pentru faza de identificare.*Figura 4.8 *Semnale de stimulație generate și de ieșire achiziționate din instalația ASTANK2, pentru faza de validare.*



Graficele aferente performanțelor de simulare ale celor două modele sunt prezentate comparativ în Figurile 4.9, care evidențiază gradul lor de concordanță față de datele reale, atât în faza de identificare, cât și în faza de validare. Pe coloana din stânga, sunt figurate semnalele aferente modelului de tip ARX. Coloana din dreapta este alocată modelului NARX. De asemenea, primele 4 figuri ale fiecărei coloane sunt asociate fazei de identificare, în timp ce ultimele 4 – fazei de validare. Figurile se succed pe o coloană în ordinea canalelor și sunt grupate în perechi: o figură pentru datele achiziționate versus datele simulate cu modelul de identificare determinat și o a doua figură pentru eroarea de modelare. Pe graficele erorilor de modelare sunt precizate dispersiile acestora și valorile estimate de SNR.






Figura 4.9 Performanțele de identificare și validare ale modelelor

Se observă că modelul de tip ARX are performanțe mai slabe decât cel de tip NARX. Acest fapt este demonstrat, de mai multe caracteristici. În primul rând, valorile dispersiei erorii de modelare sunt mai mari la modelul 2-MISO-ARX ca la modelul 2-MISO-NARX. Aceasta antrenează după sine valori mai mici de SNR. În al doilea rând, se pot compara valorile de *fitness*: **70.86%** pentru modelul 2-MISO-ARX față de **85.98%** pentru modelul 2-MISO-NARX. Mai mult, se pot observa liber diferențele mai mari dintre semnalele de ieșire simulate și cele achiziționate, în ambele faze (de identificare și validare), ale modelului de tip ARX față de modelul de tip NARX. La modelul de tip NARX, semnalele simulate se mulează destul de bine pe semnalele achiziționate. În al treilea rând, erorile de modelare sunt mai departe de comportamentul unui zgomot alb în cazul modelului 2-MISO-ARX, față de modelul 2-MISO-NARX (corelațiile dintre eșantioanele erorii sunt foarte vizibile).

Prin urmare, se poate trage concluzia că modelul 2-MISO-NARX are o dinamică mai apropiată de cea a instalației ASTANK2 decât modelul 2-MISO-ARX, ceea ce indică o mai bună capacitate a modelului NARX de a captura comportamentul al sistemului fizic. Acest fapt era de așteptat, deoarece comportamentul instalației este destul de neliniar.

## 4.4 Rezultate de control

În cazul modelului liniar, 2-MISO-ARX regulatorul PID optimal în timp continuu este caracterizat de următoarele matrici de parametri:

$$\begin{aligned} \mathbf{K}_p &= \begin{bmatrix} 1.2118 & 1.3891 \\ 0.0001 & 0.0001 \end{bmatrix}, \quad \mathbf{T}_i = \begin{bmatrix} 149.9763 & 142.1102 \\ 117.559 & 79.9664 \end{bmatrix}, \\ \mathbf{T}_d &= \begin{bmatrix} 0 & 85.675 \\ 0 & 3.9169 \end{bmatrix}, \quad \mathbf{N}_d = \begin{bmatrix} 9 & 112 \\ 6 & 9 \end{bmatrix}. \end{aligned} \quad (4.3)$$

Se poate observa că valorile parametrilor sunt destul de diferite între ele în cadrul aceleiași matrici. Pentru a produce comenzile, sunt combinate câte două regulatoare SISO-PID, dar fără ca prima eroare de urmărire să participe la componenta derivativă, deoarece  $T_{d,11} = T_{d,21} = 0$ .

Performanța acestui regulator a fost estimată la **65%**.

Matricile de parametri ale regulatorului PID optimal în timp continuu corespunzătoare modelului neliniar 2-MISO-NARX sunt următoarele:

$$\begin{aligned} \mathbf{K}_p &= \begin{bmatrix} 0.4644 & 0.3608 \\ 0.0001 & 1.7028 \end{bmatrix}, \quad \mathbf{T}_i = \begin{bmatrix} 65.5239 & 118.3820 \\ 72.5542 & 52.5444 \end{bmatrix}, \\ \mathbf{T}_d &= \begin{bmatrix} 0.0073 & 0 \\ 47.2317 & 7.6180 \end{bmatrix}, \quad \mathbf{N}_d = \begin{bmatrix} 13 & 118 \\ 5 & 26 \end{bmatrix}. \end{aligned} \quad (4.4)$$

Și în cazul lui, valorile parametrilor diferă realtiv mult între ele în cadrul aceleiași matrici. Cele două comenzi sunt sintetizate tot prin două regulatoare SISO-PID, dar ușor diferit între canale. Pentru a produce comanda pe primul canal, celui de-al doilea regulator SISO-PID îi lipsește contribuția erorii de pe canalul #2 de ieșire în configurarea componentei derivate, deoarece  $T_{d,12} = 0$ .

Performanța acestui regulator a fost estimată la **68.96%**.

Figura 4.9 prezintă rezultatele comparative de urmărire a celor două referințe alese, obținute cu cele două regulatoare PID. Timpul de simulare a fost stabilit la 2000 s, pentru a putea observa mai bine regimul staționar. Pe coloana din stânga, sunt ilustrate semnalele aferente modelului 2-MISO-ARX, iar pe cea din dreapta – semnalele modelului 2-MISO-NARX.




Figura 4.10 Performanțele de control și urmărire de referințe constante ale modelelor

Graficele din Figura 4.10 permit o analiză comparativă a celor două sisteme în buclă închisă. De notat că toate simulările au fost realizate în condiții de zgomote stocastice exogene (adăugate ieșirilor), având intensități estimate în faza de identificare. Astfel:

- Sistemul PID+ARX oferă comenzi și ieșiri mai netede decât modelul PID+NARX; în cazul celui de-al doilea, rugozitatea mai mare a semnalelor poate fi datorată și modelului 2-MISO-NARX, care este mai ușor de destabilizat numeric decât modelul 2-MISO-ARX.
- Sistemul PID+NARX are comenzi mai puțin intense ca sistemul PID+ARX. În plus, ele nu se saturează. Se pot observa saturațiile comenzilor din cazul sistemului PID+ARX, pe durate relativ lungi de timp (de peste 100 s, ajungând până la aproximativ 200 s). Aceasta expune electrovalvele la uzură prematură.
- Poate cea mai importantă diferență este aceea că sistemul PID+ARX nu reușește să urmărească una dintre referințe (cea de pe canalul 2), unde eroarea de urmărire nu se anulează în medie. În schimb, sistemul PID+NARX nu doar că urmărește bine referințele cu eroare medie nulă în regimul staționar, ci oferă și suprareglaje mult mai mici. (sub 3 mm, față de 1 cm, respectiv 1.8 cm, în cazul modelului PID+ARX). De asemenea, dispersiile calculate ale erorilor de urmărire sunt de 6-7 ori mai mici.
- Timpii de stabilizare sunt comparabili în cazul celor două sisteme (în jur de 400 s). Cel de pe canalul #2 este puțin mai lung, în ambele dinamici.

Motivul principal pentru care sistemul PID+ARX performează mai slab provine, în principal, din calitatea mai slabă a modelului de identificare. Practic, este ca și cum acest model folosește o altă hartă statică, diferită de cea reală a instalației ASTANK2, adică modelează alt sistem, înrudit cu instalația. Pentru a confirma această ipoteză, a fost inițiată o nouă căutare a regulatorului PID, dar pentru alte valori statice ale intrărilor, obținute folosind modelul de identificare și nu instalația ASTANK2. Aceste valori sunt prezentate în Tabelul 4.5.

Tabelul 4.5 *Un punct nominal de funcționare obținut cu modelul 2-MISO-ARX.*

| $y_{r1}$ [cm] | $y_{r2}$<br>[cm] | $u_{s,1}$ [V] | $u_{s,2}$ [V] |
|---------------|------------------|---------------|---------------|
| 8             | 9                | 5.25          | 7.5           |

Se observă că intrările statice din acest tabel sunt diferite (deși nu cu mult) față de cele din Tabelul 4.1 (5.25 V față de 5.39 V și, mai ales, 7.5 V față de 7.07 V).

După lansare în execuție a procedurii GWO, noul regulator PID găsit, corespunzător valorilor statice din Tabelul 4.4, are următorii parametri:

$$\mathbf{K}_p = \begin{bmatrix} 0.0067 & 0.0001 \\ 0.0091 & 1.3628 \end{bmatrix}, \mathbf{T}_i = \begin{bmatrix} 0.1419 & 23.9875 \\ 105.5758 & 71.1576 \end{bmatrix},$$

$$\mathbf{T}_d = \begin{bmatrix} 78.7748 & 0 \\ 42.4411 & 0 \end{bmatrix}, \mathbf{N}_d = \begin{bmatrix} 60 & 14 \\ 30 & 93 \end{bmatrix}. \quad (4.5)$$

În cazul acestui regulator, pentru a produce comenzile, cele două regulatoare SISO-PID, nu beneficiază de a doua eroare de urmărire în construcția componentei derivate, deoarece, acum,  $T_{d,12} = T_{d,22} = 0$ .

Performanța acestui regulator a fost estimată la **80.22%**.

Graficele din Figura 4.10 ilustrează performanța bună a acestui regulator. Totuși, el a fost proiectat pentru un model de identificare ce nu surprinde foarte bine dinamica instalației ASTANK2, fiind, practic, asociat altui sistem.




Figura 4.11 Performanțele de control și urmărire de referințe constante ale modelului

Analizând aceste grafice, se constată că, în pofida valorii mari a criteriului de performanță și a faptului că, acum, referințele sunt urmărite cu eroare nulă în medie, există deficiențe importante ale regulatorului. Astfel:

- Comenzile continuă să se satureze pe durate de cel puțin 100 s, chiar dacă aceasta permite ieșirilor să ajungă mai rapid și cu suprareglaje neglijabile la referințele impuse.
- Comanda de pe primul canal nu mai este atât de netedă ca în cazul referințelor statice originale pe intrări.

În urma acestor rezultate, se poate constata că regulatorul PID, deși este unul liniar, are performanțe mai bune în conjuncție cu modelul neliniar 2-MISO-NARX decât împreună cu modelul liniar 2-MISO-ARX. Acest comportament era de așteptat, prin prisma faptului că modelul neliniar surprinde mai bine dinamica instalației ASTANK2, care, în esență, este una cauzată de fenomene de curgere hidraulică descrise de modele analitice neliniare.

## 5 Concluzii și perspective

Lucrarea de față a explorat în mod integral procesul de identificare a unui sistem multi-variabil, urmat de proiectarea și testarea a unui regulator PID optimizat, de asemenea multi-variabil (nedecuplat), acordat prin intermediul algoritmului metaeuristic *Grey Wolf Optimizer* (GWO). Modelul de identificare principal a fost de tip 2-MISO-NARX, neliniar, cu scopul de a îmbunătăți performanțele de control într-un cadru simulativ apropiat de realitate. În subsidiar, un alt model, de tip 2-MISO-ARX, liniar, a fost de asemenea identificat și analizat, spre comparație.

Prin compararea modelelor de tip ARX și NARX, s-a evidențiat diferența fundamentală dintre cele două abordări în captarea dinamicii sistemului. Modelul de tip NARX a demonstrat o capacitate superioară în a aproxima comportamentul complexe al sistemului studiat și a servit drept bază solidă pentru proiectarea unui regulator PID cu bune performanțe.

Utilizarea algoritmului GWO în etapa de optimizare a permis determinarea parametrilor optimali ai regulatorului PID, fapt ce s-a dovedit a fi benefic, întrucât această metauristică s-a remarcat printr-un echilibru eficient între explorarea și exploatarea spațiului de căutare, generând soluții stabile satisfăcătoare într-un număr rezonabil de iterații.

Testarea regulatorului într-un mediu simulativ realist, reprezentat de sistemul ASTANK2, a permis analiza performanțelor, cu accent pe urmărirea referințelor și minimizarea erorilor staționare. Rezultatele au arătat că integrarea modelului de tip NARX cu un PID optimizat aduce beneficii clare în ceea ce privește precizia și viteza de răspuns, validând astfel ipoteza că o arhitectură de control bazată pe modelare neliniară poate reflecta mai fidel realitatea sistemelor complexe.

Chiar dacă rezultatele de simulare au fost concludente, se conturează o serie de perspective legate de continuarea acestei abordări. În primul rând regulatorul PID poate fi testat în diferite scenarii cu referințe variabile și alte tipuri de perturbații decât cele stocastice (de exemplu, cele deterministe constante adăugate ieșirilor sistemului). În al doilea rând se poate analiza pe larg robustețea soluției de reglare automată, prin capacitatea de rejecție a incertitudinilor de modelare sau a celor legate de perturbații. În fine, în al treilea rând, s-ar putea încerca înlocuirea modelului de tip 2-MISO cu un model MIMO, tot neliniar. Această ultimă perspectivă este justificată de particularitățile constructive ale instalației ASTANK2, care permite, totuși, comunicarea între rezervoare, deci considerarea influențelor reciproce dintre cele două ieșiri.

Concluzionând, această lucrare demonstrează fezabilitatea și eficiența unei strategii de control bazate pe modelare avansată și optimizare inteligentă. Metodologia propusă oferă un cadru flexibil, adaptabil și extensibil pentru aplicații viitoare în controlul sistemelor neliniare, reprezentând o contribuție semnificativă la dezvoltarea soluțiilor moderne de automatizare.



## 6 Contribuții personale

- Adaptarea și particularizarea algoritmului *Grey Wolf Optimizer* (GWO) pentru problema determinării parametrilor optimali ai unui PID multi-variabil, destinat controlului unui sistem neliniar de tip multi-MISO.
- Implementarea funcției *fitness* adecvate pentru evaluarea performanței regulatorului.
- Verificarea și validarea rezultatelor algoritmului GWO, prin simulări repetate și interpretarea convergenței parametrilor obținuți.
- Integrarea regulatorului PID optimizat în arhitecturi de control bazate pe modele 2-MISO-ARX și 2-MISO-NARX, urmată de comentarii comparative privind performanțele și acuratețea celor două sisteme în buclă închisă.



## Bibliografie

- [CuSt-2017] Culiță J., Ștefănoiu D. – Multi-Model Identification of Pumping System in ASTANK2 Plant, The 21th International Conference on Control Systems and Computer Science – CSCS21 (ISBN 978-1-5386-1839-4), Bucharest, Romania, pp. 59–66, May 29–31, 2017.
- [CuStDu-2015] Culiță J., Ștefănoiu D., Dumitrașcu A. – ASTANK2: Analytical Modeling and Simulation, The 20th International Conference on Control Systems and Computer Science – CSCS20 (ISBN 978-1-4799-1780-8), Bucharest, România, pp. 141–148 (Vol. 1), May 27–29, 2015.
- [GWO-2018] <http://www.mathworks.com/matlabcentral/fileexchange/47258-grey-wolf-optimizer-toolbox>
- [Hake-99] Haber R.; Keviczky L. – Nonlinear System Identification—Input Output Modeling Approach; Kluwer Academic Publishers (ISBN: 978-0-7923-5858-9), Dordrecht, The Netherlands, 1999.
- [Mir-2014] Mirjalili S., Mirjalili S. M., Lewis A. – Grey Wolf Optimizer, *Advances in Engineering Software* (ISSN 0965-9978), Vol. 69, pp. 46–61, March 2014.
- [RoMeVi-2020] Rodriguez-Molina A., Mezura-Montes E., Villarreal-Cervantes M.G., Aldape-Perez M. – *Multi-Objective Meta-Heuristic Optimization in Intelligent Control: A Survey on the Controller Tuning Problem*, *Applied Soft Computing*, no. 93, 2020.
- [SBPFE-2014] Ștefănoiu D., Borne P., Popescu D., Filip F.G., El Kamel A. – Optimization in Engineering Sciences—Metaheuristics, Stochastic Methods and Decision Support. John Wiley & Sons & ISTE Press, London, UK (ISBN: 978-1-84821-498-9), 2014.
- [SCVV-2024] Ștefănoiu D., Culiță J., Voinea A.C., Voinea V. – Nonlinear Identification for Control by using NARMAX Models, *Mathematics Journal, Section Engineering Mathematics*, Vol. 12, No. 14, article #2252, July 2024.
- [StCu-2020] Ștefănoiu D., Culiță J. – *Joint Stochastic Spline and Autoregressive Identification Aiming Order Reduction Based on Noisy Sensor Data*, *Sensors Journal*, Vol. 20, No. 18, article #5038, September 2020.
- [StCu-2021] Ștefănoiu D., Culiță J. – *Optimal Identification and Metaheuristic PID Control of a Two-Tank System*, *Electronics Journal, Special Issue on "Control of Nonlinear Systems and Industrial Processes"* (ISSN 2079-9292, EISSN 2079-9292), Vol. 10, No. 9, article #1101, May 2021.
- [StCuSt-2005] Ștefănoiu D., Culiță J., Stoica P. – *Fundamentele modelării și identificării sistemelor*, Editura Printech (ISBN: 973-718-368-1), București, România, Decembrie 2005.